

深度残差网络定性 Scaling Law 的严格证明

摘要

本文证明：对于带有归一化（RMSNorm 或 LayerNorm）的深度残差网络，在温和条件下，增加模型深度、宽度和训练数据量均能改善泛化性能。证明将 scaling 机制分解为三个部分：(1) 深度通过零初始化处**存在负的一阶方向导数**来保证严格更优的模型**存在**（定理 1）；(2) 宽度放大改善信号的强度，使改善在有限样本下更易被可靠观测（第 7.6 节）；(3) 新增残差层的泛化代价随数据量增长而**消失**（引理 3）。主定理（定理 4A 与定理 4B）给出测试集上的 scaling 改善不等式：定理 4A 经由总体风险层面建立 $\Delta_R/2$ 的确定性 margin 后通过 Hoeffding 转移到测试集；定理 4B 则**完全在训练集/测试集层面工作**，不引入任何 Hoeffding，并允许 $\Delta_R^{test} = 0$ 。两条路径互为补充——4A 在 $\Delta_R > 0$ 、 $M \gg K$ 的常规情形下泛化代价更紧（系数 $2\epsilon_M$ ），4B 在 $\Delta_R \rightarrow 0$ 的退化情形下天然鲁棒（系数 $2(\epsilon_M + \epsilon_K)$ ，但允许 $\Delta_R^{test} = 0$ ），并存构成稳健的双重严格化。全部论证仅需损失函数的 C^1 正则性，不需要 Hessian 有界等二阶条件。在额外的建模假设（假设 G）下，进一步推导出幂律形状 $R - R^* \sim P^{-\alpha}$ 。

第一章 问题设定

1.1 数据与风险

设 $\mathcal{D}$ 为 $\mathcal{X} \times \mathcal{Y}$ 上的数据分布。训练集 $S_{train} = \{(x_i, y_i)\}_{i=1}^M \stackrel{\text{i.i.d.}}{\sim} \mathcal{D}^M$ ，独立测试集 $S_{test} = \{(\tilde{x}_j, \tilde{y}_j)\}_{j=1}^K \stackrel{\text{i.i.d.}}{\sim} \mathcal{D}^K$ 。损失函数 ℓ 取值于 $[0, B_\ell]$ 。

定义**经验训练风险**（有限训练样本上的平均损失）：

$$\mathcal{L}_{train}(f) = \frac{1}{M} \sum_{i=1}^M \ell(f(x_i), y_i)$$

定义**总体风险**（在整个数据分布上的期望损失）：

$$R(f) = \mathbb{E}_{(x,y) \sim \mathcal{D}}[\ell(f(x), y)]$$

$R(f)$ 是我们真正想最小化的目标——它衡量模型在所有可能数据（包括从未见过的）上的平均表现。但 $R(f)$ 无法直接计算（因为 $\mathcal{D}$ 未知），只能通过有限样本的 $\mathcal{L}_{train}(f)$ 近似。泛化理论的核心任务就是控制 $|R(f) - \mathcal{L}_{train}(f)|$ 。

1.2 网络分解与梯度

在第 l 层处将网络分解为 $f = f_{top} \circ f_{bot}$ ：

- 底层** $f_{bot} : \mathcal{X} \rightarrow \mathbb{R}^N$ ：将输入映射到 N 维隐层表示。
- 顶层** $f_{top} : \mathbb{R}^N \rightarrow \mathbb{R}^C$ ：将隐层表示映射到输出。

第 i 个训练样本的隐层表示记为 $x_i^{(l)} = f_{bot}(x_i)$ 。

定义以下梯度量：

训练集平均梯度（可从训练数据直接计算）：

$$\mu = \frac{1}{M} \sum_{i=1}^M \nabla_{x_i^{(l)}} \ell(f_{top}(x_i^{(l)}), y_i) \in \mathbb{R}^N$$

总体平均梯度（理论量，无法直接计算）：

$$\bar{\mu} = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\nabla_{x^{(l)}} \ell(f_{top}(x^{(l)}), y)] \in \mathbb{R}^N$$

由大数定律，当 $M \rightarrow \infty$ 时 $\mu \rightarrow \bar{\mu}$ 。

对每个测试样本 j ，定义**单样本梯度** $\zeta^{(j)} = \nabla_{\tilde{x}_j^{(l)}} \tilde{\ell}_j$ ，以及**测试集平均梯度** $g = \frac{1}{K} \sum_{j=1}^K \zeta^{(j)}$ 。因测试集独立于训练集， $\mathbb{E}[g] = \bar{\mu}$ 。

1.3 假设空间与模型扩展

定义 1（旧假设空间与旧模型） 深度扩展之前，网络所能表示的全部函数构成**旧假设空间**：

$$\mathcal{H}_{old} = \{x \mapsto f_{top}(f_{bot}(x)) : f_{top} \in \mathcal{F}_{top}, f_{bot} \in \mathcal{F}_{bot}\}$$

设 $f_{old}^* \in \mathcal{H}_{old}$ 为旧空间中某个已训练的模型。

定义 2（新假设空间） 在第 l 层后插入一个新的残差块 h ，将中间表示 $x^{(l)}$ 映射为 $x^{(l)} + h(x^{(l)})$ 。新残差块所能表示的函数类记为 $\mathcal{F}_{res}$ 。由此得到的**新假设空间**为：

$$\mathcal{H}_{new} = \{x \mapsto f_{top}(f_{bot}(x) + h(f_{bot}(x))) : f \in \mathcal{H}_{old}, h \in \mathcal{F}_{res}\}$$

当 $h = 0$ 时退化为旧模型，因此 $\mathcal{H}_{old} \subseteq \mathcal{H}_{new}$ 。

我们对 $\mathcal{F}_{res}$ 施加两个条件，分别服务于证明的不同环节：

(a) 零点一阶可下降性（表达能力） $\mathcal{F}_{res}$ 以参数 θ 参数化， $h_0 = 0$ （零初始化对应旧模型），且在 $\theta = 0$ 处光滑。存在参数方向 v 使得：

$$\mathbb{E}_{(x,y) \sim \mathcal{D}} \left[\nabla_{x^{(l)}} \ell(f_{top}(x^{(l)}), y)^T \cdot \left. \frac{\partial h_\theta(x^{(l)})}{\partial \theta} \right|_{\theta=0} \cdot v \right] \neq 0$$

若上式为正，则将 v 替换为 $-v$ ，即可得到负方向导数。

直觉：这只要求残差块在零初始化处“不是死的”——存在某个参数方向能与**真实的总体风险一阶导数**产生非零耦合。此条件远弱于“覆盖整个零点邻域”——我们不需要 $\mathcal{F}_{res}$ 能表示所有方向的常数偏移，只需要在某个方向上确实能让总体风险的一阶变化不为零。

这是定理 1 真正需要控制的量：若定义路径 $\theta(t) = tv$ ，则

$$G(t) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_{top}(x^{(l)} + h_{tv}(x^{(l)})), y)]$$

的导数满足

$$G'(0) = \mathbb{E} \left[\nabla_{x^{(l)}} \ell(f_{top}(x^{(l)}), y)^T \cdot \left. \frac{\partial h_\theta(x^{(l)})}{\partial \theta} \right|_{\theta=0} \cdot v \right].$$

因此条件 (a) 直接控制的就是总体风险沿跳板路径的真实一阶方向导数，而不是 $\bar{\mu}$ 与某个平均 Jacobian 的形式内积。

含偏置项的充分条件：若残差块 h_θ 在零初始化处对某个偏置参数 b 的一阶导数满足 $\frac{\partial h_\theta(x^{(l)})}{\partial b}\Big|_{\theta=0} = I$ ，则对任意 $\bar{\mu} \neq 0$ ，取偏置方向 $v = -\bar{\mu}$ 有

$$\mathbb{E} \left[\nabla_{x^{(l)}} \ell(f_{top}(x^{(l)}), y)^T \cdot \frac{\partial h_\theta(x^{(l)})}{\partial b} \Big|_{\theta=0} \cdot (-\bar{\mu}) \right] = -\bar{\mu}^T \bar{\mu} = -\|\bar{\mu}\|^2 < 0.$$

因而条件 (a) 自动成立。**注意：**此结论适用于输出端**未接归一化层**的偏置项。对输出端再接 RMSNorm/LayerNorm 的残差块（如例 2-3），在 $\theta = 0$ 处整个块的输出为 RMSNorm(0)，可能不可微或 Jacobian 退化，条件 (a) 不能仅由“含偏置项”自动推出，需要额外验证。

与 $\bar{\mu}$ 的关系：设

$$J(x) = \frac{\partial h_\theta(x^{(l)})}{\partial \theta} \Big|_{\theta=0}$$

为零点处的参数 Jacobian。条件 (a) 要求的是某个方向 v 使

$$\mathbb{E}[(\nabla_{x^{(l)}} \ell)^T J(x)v] \neq 0.$$

若 $J(x)v \equiv u$ 恰好是与样本无关的常向量，则它退化为 $\bar{\mu}^T u \neq 0$ 。因此：对“能产生常向量扰动”的残差块， $\bar{\mu} \neq 0$ 是一个方便的充分条件；但在一般情形下， $\bar{\mu} = 0$ **并不自动否定** 条件 (a)，因为数据依赖的 $J(x)v$ 仍可能与逐点梯度发生相关，从而给出非零的一阶导数。

注意条件 (a) 失效弱于“表示最优”（定义 5，要求逐点梯度为零）：逐点梯度为零会强迫条件 (a) 对所有方向都失效；但仅有 $\bar{\mu} = 0$ 时，条件 (a) 仍可能成立。

(b) 复杂度可控（泛化能力） 存在函数 $\psi: \mathbb{N} \rightarrow \mathbb{R}_{>0}$ （称为**复杂度包络**），满足 $\psi(M) \rightarrow 0$ ($M \rightarrow \infty$)，且对任意大小为 M 的 i.i.d. 训练集 S ：

$$\hat{\mathfrak{R}}_S(\mathcal{F}_{res}) \leq \psi(M)$$

$\psi(M)$ 量化了残差块函数类的有效自由度随数据量的缩减速率。此条件服务于讨论中的引理 2（第 8.8 节，跳板子空间的更紧泛化界）。主链路的泛化控制由引理 3 提供，不直接使用条件 (b)。

满足两个条件的典型残差块：

例 1（Linear-ReLU-Linear） $h(x) = W_2 \sigma(W_1 x + b_1) + b_2$ （输出端无归一化），谱范数约束 $\|W_1\|_\sigma \leq s_1$ ， $\|W_2\|_\sigma \leq s_2$ 。条件 (a)：在 $\theta = 0$ 处 $\frac{\partial h}{\partial b_2} = I$ 。因此当 $\bar{\mu} \neq 0$ 时，取偏置方向 $v = -\bar{\mu}$ ，有真实方向导数 $G'(0) = -\|\bar{\mu}\|^2 < 0$ ，故条件 (a) 自动满足。条件 (b) 由 Golowich, Rakhlin & Shamir (2018) 给出 $\psi(M) = \mathcal{O}(s_1 s_2 R \sqrt{\log N} / \sqrt{M})$ ，其中 $R = \max_i \|x_i^{(l)}\|$ 。

例 2（Conv-ReLU-Conv-ReLU-RMSNorm） ResNet 的标准残差块。条件 (a)：由于输出端接了 RMSNorm，在 $\theta = 0$ （所有权重和偏置为零）处块的输出为 RMSNorm(0)，不可直接套用上面的偏置型充分条件。条件 (a) 需要单独验证——在实际 Pre-LN 架构中，通常通过特定的初始化方案（如残差分支的最后一层权重初始化为小量而非精确零）来保证零点附近存在真实的一阶下降方向。条件 (b)：卷积核谱范数有界时， $\psi(M) = \mathcal{O}(\|K_1\|_\sigma \|K_2\|_\sigma R \sqrt{\log N} / \sqrt{M})$ 。

例 3（Linear-GeLU-Linear-RMSNorm） Transformer FFN 块。条件 (a) 的情况与例 2 类似——输出端的 RMSNorm 使得零初始化处的方向导数分析需要额外注意。条件 (b) 与例 1 平行。

反例 “所有满足 $\|h(x)\| \leq B$ 的函数”**不满足** (b)——其 Rademacher 复杂度为 $\Theta(B)$ ，不随 M 衰减。

定义 3（跳板模型的存在性） 若条件 (a) 成立，则新假设空间 $\mathcal{H}_{new}$ 中**存在**一个总体风险严格低于旧模型的元素。我们将这样的元素称为**跳板模型** $\tilde{f}$ 。

关键区别：我们只需要跳板模型**存在**，不需要显式构造它，更不需要在实际训练中找到它。它的唯一角色是证明新假设空间“比旧假设空间严格更好”。实际训练得到的模型 f_{new} 可能走了完全不同的路径——它只需不比跳板差即可（定理 4A 条件 (ii)）。

1.4 泛化界的基本工具

定义 4（经验 Rademacher 复杂度） 给定函数类 $\mathcal{G}$ 和样本 $z_1, \dots, z_M$ ：

$$\hat{\mathfrak{R}}_S(\mathcal{G}) = \mathbb{E}_\sigma \left[\sup_{g \in \mathcal{G}} \frac{1}{M} \sum_{i=1}^M \sigma_i g(z_i) \right]$$

其中 σ_i 为 i.i.d. Rademacher 变量（等概率取 ± 1 ）。

命题 1（经典泛化界） 以至少 $1 - \delta$ 的概率，对所有 $f \in \mathcal{F}$ 同时成立：

$$|R(f) - \mathcal{L}_{train}(f)| \leq 2\hat{\mathfrak{R}}_S(\ell \circ \mathcal{F}) + 3B_\ell \sqrt{\frac{\ln(2/\delta)}{2M}}$$

简记为 $\epsilon_{gen}(\mathcal{F}, M, \delta)$ 。

第二章 假设

本章集中列出全文所需的全部假设。假设 1 与假设 2(a) 服务于定理 1（存在性）；假设 1、2(a)、3 和 5 服务于定理 3、定理 4A 和定理 4B，其中假设 3（Lipschitz）和假设 5（L1, L2, N, B）通过引理 3（泛化控制）进入；假设 2(b) 仅在第 8.8 节的引理 2 中作为可选改进使用；假设 4 服务于定理 2（梯度方向对齐），并在定理 4B 的非退化情形下作为 $\Delta_R^{test} \geq 0$ 的概率支撑。

假设 1（ C^1 正则性） 映射 $v \mapsto \mathbb{E}_{(x,y) \sim \mathcal{D}}[\ell(f_{top}(x^{(l)} + v), y)]$ 在 $v = 0$ 的邻域内连续可微。

标准损失（交叉熵 + Softmax、MSE + 有界激活）在紧集上自然满足。此条件严格弱于 Hessian 一致有界。

假设 2（残差块条件） $\mathcal{F}_{res}$ 满足定义 2 中的条件 (a)；条件 (b) 在第 8.8 节的引理 2 中另行使用，不进入主定理链路。

例 1 的残差块（输出端无归一化）在谱范数有界时自动满足条件 (a)，因为偏置方向直接给出 $G'(0) = -\|\bar{\mu}\|^2 < 0$ 。

例 2–3 的残差块（输出端接 RMSNorm）满足条件 (b)，但条件 (a) 需要额外验证零初始化处的方向导数非退化性。

假设 3（Lipschitz 有界性） 损失 ℓ 是 L_ℓ -Lipschitz 的。顶层映射 f_{top} 是 L_{top} -Lipschitz 的（ $L_{top} < \infty$ ），且满足参考点有界性 $\|f_{top}(0)\| \leq B_0$ 。

Pre-LN 残差网络中，若 $(L - l)\gamma \leq C_0$ ，则 $L_{top} \leq e^{C_0}$ 。参考点有界性在常见输出头（线性层、MLP 头）中通常由偏置或零点输出的有界性自动满足。

假设 4（梯度协方差谱范数有界） 激活梯度 $\zeta = \nabla_{x^{(l)}} \ell$ 的协方差矩阵满足 $\lambda_{\max}(\Sigma) \leq C_\Sigma \tau^2$ ，其中 $\tau^2 \geq \text{Var}(\zeta_1)$ ， $C_\Sigma > 0$ 为不依赖 N 的常数。

此假设仅在定理 2（梯度方向对齐）中使用。可直接作为公理接受，也可通过归一化层的置换等变性 + 高维去相关从架构层面 justify（详见 §8.3 评注）。

假设 5（网络结构正则性——服务于泛化控制） L 层残差网络 $T_l(z) = N_l(z + h_l(z))$ 满足：

(L1) 残差支路对输入的 Lipschitz 性： $h_l(\cdot; W_l)$ 对输入 z 的 Lipschitz 常数至多为 s_l 。

(L2) 残差支路对参数的 Lipschitz 性：

$$\|h_l(z; W_l) - h_l(z; W'_l)\| \leq L_l^{(p)} \|W_l - W'_l\|_F \cdot \|z\|$$

其中 $L_l^{(p)}$ 为不依赖 z, W_l 的常数。

对线性残差支路 $h_l(z; W_l) = W_l z$, $L_l^{(p)} = 1$ 。对两层残差块 $h_l(z) = W_2 \sigma(W_1 z + b)$, $L_l^{(p)}$ 依赖于各层权重范数上界。

(N) 归一化层前的非退化性：

$$\inf_{x, \theta \in \Theta, l} \|z_l(x) + h_l(z_l(x); \theta)\| \geq r_{\min} > 0$$

此条件保证归一化层的 Lipschitz 常数有统一上界（见引理 3 第二步）。第 8.9 节给出两条将此条件弱化或消除的路径：

(1) 引入工程 ϵ （实际框架中始终存在）；(2) 在 $s_l < 1$ 和 $\gamma_{\min} > 0$ 下将 (N) 证明为推论。

(B) 范数约束： 各层残差支路参数满足 $\|W_l\|_{\sigma} \leq s_l$, $\|W_l\|_F \leq b_l$ 。输入满足 $\|x\| \leq R$ 。

第三章 定理 1：深度保证总体风险下降

定理 1（深度的价值） 在假设 1 和假设 2(a) 成立的前提下，新假设空间 $\mathcal{H}_{new}$ 中存在跳板模型 $\tilde{f}$ （定义 3），满足 $R(\tilde{f}) < R(f_{old}^*)$ 。

定理 1 直接以“零初始化处存在负的一阶方向导数”作为前提，不再要求 $\bar{\mu} \neq 0$ 。在输出端无归一化且含偏置的特例中， $\bar{\mu} \neq 0$ 仍然是一个易检验的充分条件，因为此时可取常向量偏置方向得到 $G'(0) = -\|\bar{\mu}\|^2$ 。另一方面，若第 l 层已达到表示最优（定义 5：逐点激活梯度为零），则任何参数方向的一阶方向导数都为零，定理 1 的前提不成立。注意此定理不需要训练集浓缩条件——跳板模型的存在性完全由总体分布决定。训练集浓缩条件仅在定理 2（梯度方向对齐）中出现，用于控制有限样本效果。

证明

第一步：构造参数空间中的下降路径。

由假设 2(a)（零点一阶可下降性），存在参数方向 v 使得

$$a \triangleq \mathbb{E}_{(x,y) \sim \mathcal{D}} \left[\nabla_{x^{(l)}} \ell(f_{top}(x^{(l)}), y)^T \cdot \frac{\partial h_{\theta}(x^{(l)})}{\partial \theta} \Big|_{\theta=0} \cdot v \right] \neq 0$$

若 $a > 0$ ，将 v 替换为 $-v$ ，使 $a < 0$ 。考虑路径 $\theta(t) = tv$ ($t \geq 0$)，定义沿此路径的总体风险：

$$G(t) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_{top}(x^{(l)} + h_{tv}(x^{(l)})), y)]$$

则 $G(0) = R(f_{old}^*)$ 。

第二步：计算 $G'(0)$ 。

由假设 1 (C^1 正则性) 和链式法则：

$$G'(0) = \mathbb{E} \left[\nabla_{x^{(l)}} \ell(f_{top}(x^{(l)}), y)^T \cdot \frac{\partial h_{tv}(x^{(l)})}{\partial t} \Big|_{t=0} \right] = \mathbb{E} \left[\nabla_{x^{(l)}} \ell(f_{top}(x^{(l)}), y)^T \cdot \frac{\partial h_{\theta}(x^{(l)})}{\partial \theta} \Big|_{\theta=0} \cdot v \right] = a < 0$$

第三步：由导数为负推出存在性。

$G'(0) < 0$ 且 G 连续，故存在 $t_0 > 0$ 使 $G(t_0) < G(0)$ 。对应 $\theta_0 = t_0 v$ 给出 $h_{\theta_0} \in \mathcal{F}_{res}$ ，跳板模型 $\tilde{f}$ 满足 $R(\tilde{f}) = G(t_0) < R(f_{old}^*)$ 。■

注 1：证明只需跳板模型**存在**，不需要显式构造或计算 t_0 的值。

注 2： t_0 和 $\Delta_R = G(0) - G(t_0)$ 仅依赖总体风险函数 G 的局部形状（由分布 $\mathcal{D}$ 和当前模型决定），不涉及训练集或测试集。

注 3（含偏置项的特例）：对例 1（输出端无归一化）的残差块， $\frac{\partial h}{\partial b_2} \Big|_{\theta=0} = I$ ，取 v 为偏置方向 $-\bar{\mu}$ 即得 $a = -\|\bar{\mu}\|^2 < 0$ ， $G'(0) = -\|\bar{\mu}\|^2$ 。对例 2-3（输出端接 RMSNorm），条件 (a) 的验证需要额外注意零初始化处的可微性与方向导数非退化性（见第 1.3 节例 2-3 的讨论）。定理本身对所有满足条件 (a) 的 $\mathcal{F}_{res}$ 成立。

第四章 定理 2：宽度保证梯度方向对齐

定理 2（宽度的价值） 在假设 4 ($\lambda_{\max}(\Sigma) \leq C_{\Sigma} \tau^2$) 成立的前提下，若：

(i) 总体平均梯度非零： $\bar{\mu} \neq 0$ ；

(ii) 训练集足够大： $M \geq M_1$ ，使得 $\|\mu - \bar{\mu}\| < \|\bar{\mu}\|/2$ ；

则测试集平均梯度与训练集平均梯度方向一致的概率满足：

$$P(\mu^T g \leq 0) \leq \frac{9C_{\Sigma}\tau^2}{K\|\bar{\mu}\|^2}$$

当 $K\|\bar{\mu}\|^2 \rightarrow \infty$ 时，此概率趋于零。特别地，若各分量梯度均匀活跃 ($\|\bar{\mu}\|^2 = \Theta(N)$)，则概率界为 $\mathcal{O}(1/(KN))$ 。

证明

第一步：计算 $\mathbb{E}[\mu^T g]$ 的下界。

条件于训练集， $\mathbb{E}[g] = \bar{\mu}$ ，因此：

$$\mathbb{E}[\mu^T g \mid S_{train}] = \mu^T \bar{\mu}$$

由条件 (ii) ($\|\mu - \bar{\mu}\| < \|\bar{\mu}\|/2$)，分解 $\bar{\mu}^T \mu = \|\bar{\mu}\|^2 + \bar{\mu}^T (\mu - \bar{\mu})$ ，由 Cauchy-Schwarz：

$$|\bar{\mu}^T (\mu - \bar{\mu})| \leq \|\bar{\mu}\| \|\mu - \bar{\mu}\| < \|\bar{\mu}\|^2/2$$

故 $\mu^T \bar{\mu} > \|\bar{\mu}\|^2/2 > 0$ 。令 $\alpha \triangleq \mu^T \bar{\mu} > \|\bar{\mu}\|^2/2$ 。

$$\mathbb{E}[\mu^T g] = \alpha > \|\bar{\mu}\|^2/2 > 0 \tag{I}$$

第二步：计算 $\text{Var}(\mu^T g)$ 的上界。

$$\text{Var}(\mu^T g \mid S_{train}) = \mu^T \text{Cov}(g) \mu = \frac{1}{K} \mu^T \Sigma \mu$$

其中 $\Sigma = \text{Cov}(\zeta)$ 为单样本梯度的协方差矩阵。由 $\lambda_{\max}(\Sigma) \leq C_\Sigma \tau^2$ ：

$$\lambda_{\max}(\Sigma) \leq C_\Sigma \tau^2$$

因此：

$$\text{Var}(\mu^T g) = \frac{1}{K} \mu^T \Sigma \mu \leq \frac{C_\Sigma \tau^2 \|\mu\|^2}{K} \quad (\text{II})$$

第三步：应用 Chebyshev 不等式。

Chebyshev 不等式的单侧形式：若 $\mathbb{E}[X] = \alpha > 0$, $\text{Var}(X) = \sigma^2$, 则

$$P(X \leq 0) \leq P(|X - \alpha| \geq \alpha) \leq \frac{\sigma^2}{\alpha^2}$$

第一步： $X \leq 0$ 意味着 X 偏离均值 α 至少 α (因为 $|X - \alpha| \geq \alpha - X \geq \alpha$)。第二步：标准 Chebyshev。

应用于 $X = \mu^T g$, 由 (I) ($\alpha > \|\bar{\mu}\|^2/2$) 和 (II)：

$$P(\mu^T g \leq 0) \leq \frac{C_\Sigma \tau^2 \|\mu\|^2 / K}{(\|\bar{\mu}\|^2/2)^2} = \frac{4C_\Sigma \tau^2 \|\mu\|^2}{K \|\bar{\mu}\|^4}$$

在条件 (ii) 下 $\|\mu\| < 3\|\bar{\mu}\|/2$, 故 $\|\mu\|^2 < 9\|\bar{\mu}\|^2/4$ ：

$$P(\mu^T g \leq 0) \leq \frac{9C_\Sigma \tau^2}{K \|\bar{\mu}\|^2} \quad (\text{III})$$

当 $K \|\bar{\mu}\|^2 \rightarrow \infty$ 时, 此概率趋于零。■

注：若各分量梯度均匀活跃 ($\|\bar{\mu}\|^2 = \Theta(N)$), 则概率界为 $\mathcal{O}(C_\Sigma \tau^2 / (KN))$ 。在归一化架构下, C_Σ 通常接近 $1 + \rho$ ($\rho = \mathcal{O}(1)$)；对 LayerNorm ($c = -v/(N-1)$) 可以得到更紧的常数。详见 §8.3 评注。

第五章 引理 3：基于范数的泛化控制

引理 3 (归一化残差网络的损失类 Rademacher 复杂度界) 在假设 3 和假设 5 成立的前提下, 经验 Rademacher 复杂度满足：

$$\hat{\mathfrak{R}}_S(\ell \circ \mathcal{H}) \leq B_\ell \sqrt{\frac{2d \log(2\bar{b} L L_\ell \Lambda_{\max} / \epsilon_0 + 1)}{M}} + \epsilon_0$$

其中 $R_{norm} = \gamma_{\max} \sqrt{N}$ 为归一化后的表示范数上界, $R_* = \max\{R, R_{norm}\}$, $\Lambda_{\max} = \max_l \Lambda_l$, $\Lambda_l = L_{top} \cdot L_l^{(p)} \cdot R_* \cdot c_l \cdot \prod_{k \geq l} c_k (1 + s_k)$ 为第 l 层参数扰动对顶层输出的放大系数, $d = \sum_{l=0}^{L-1} d_l$ 为总参数维度, $\bar{b} = \max_l b_l$ 。取 $\epsilon_0 = 1/\sqrt{M}$ 后,

$$\hat{\mathfrak{R}}_S(\ell \circ \mathcal{H}) = \mathcal{O}\left(B_\ell \sqrt{\frac{d \log M}{M}}\right)$$

简记此界为 $\epsilon_{gen}^{norm}(\mathcal{H}, M, \delta)$ (含 $\sqrt{\ln(1/\delta)/M}$ 的集中项)。

证明

第一步：归一化截断输入空间。

设 RMSNorm 的逐坐标缩放参数为 $\gamma = (\gamma_1, \dots, \gamma_N)$ 。对任意 $x \neq 0$ ，RMSNorm 的输出第 i 分量为 $\gamma_i x_i / \text{RMS}(x)$ ，故：

$$\|\text{RMSNorm}(x)\|^2 = N \cdot \frac{\sum_i \gamma_i^2 x_i^2}{\sum_j x_j^2} \leq N \gamma_{\max}^2$$

其中 $\gamma_{\max} = \max_i |\gamma_i|$ 。因此 $\|\text{RMSNorm}(x)\| \leq \gamma_{\max} \sqrt{N} \triangleq R_{\text{norm}}$ 。当 γ 为常数向量时取等。对 LayerNorm 类似地有 $\|\text{LayerNorm}(x)\| \leq \gamma_{\max} \sqrt{N}$ 。

这意味着**无论输入范数多大，经过归一化后的表示范数被约束在 $O(\sqrt{N})$** 。每层的输入范数不随深度增长。

第二步：逐层 Lipschitz 常数（对输入）。

对第 l 层映射 $T_l(z) = N_l(z + h_l(z))$ ，对任意 u, v ：

残差部分（由条件 L1）：

$$\|(u + h_l(u)) - (v + h_l(v))\| \leq (1 + s_l)\|u - v\|$$

归一化部分：由条件 (N)，归一化层的输入满足 $\|u\| \geq r_{\min} > 0$ 。RMSNorm 的 Jacobian 为 $\frac{1}{r} \text{diag}(\gamma)(I - \hat{x}\hat{x}^T)$ （其中 $r = \text{RMS}(u) = \|u\|/\sqrt{N}$ ， $\hat{x} = u/\|u\|$ ），其算子范数至多为 $2\gamma_{\max}/r = 2\gamma_{\max}\sqrt{N}/\|u\|$ 。由 $\|u\| \geq r_{\min}$ ，得 Lipschitz 常数的统一上界：

$$c_l \leq \frac{2\gamma_{\max}\sqrt{N}}{r_{\min}}$$

因此：

$$\|T_l(u) - T_l(v)\| \leq c_l(1 + s_l)\|u - v\|$$

条件 (N) 何时自然成立：若各层表示满足 $\|z_l\| = \Theta(\sqrt{N})$ （由第一步的归一化截断保证），且残差支路满足相对幅值控制 $\|h_l(z_l)\| \leq \alpha\|z_l\|$ ($\alpha < 1$)，则

$$\|z_l + h_l(z_l)\| \geq (1 - \alpha)\|z_l\| = \Theta(\sqrt{N})$$

因而 $r_{\min} = \Theta(\sqrt{N})$ ，从而 $c_l = O(\gamma_{\max})$ 。在 $\gamma_{\max} = O(1)$ （标准初始化）时 $c_l = O(1)$ 。

相对幅值控制 $\alpha < 1$ 在谱范数约束 s_l 较小时自然成立（ $\|h_l(z_l)\| \leq s_l\|z_l\|$ ，取 $\alpha = s_l$ ）。Pre-LN Transformer 中 $s_l = O(1/L)$ ，故 $\alpha \ll 1$ 。

但此条件**不是无条件成立的**：在极端参数配置下（ s_l 接近或超过 1）， $z_l + h_l(z_l)$ 可能接近零， c_l 爆掉。条件 (N) 需要显式验证。

第三步：顶层输出落在统一有界区域内。

整网输出为 $f_\theta(x) = f_{\text{top}}(z_L)$ ，其中 $z_L = T_{L-1} \circ \dots \circ T_0(x)$ 。我们先控制 $\|z_L\|$ 。

网络采用 Pre-LN 结构（每一层输出经过归一化），因此**每一层的输出范数都被归一化截断**。具体地：

- 输入 x 经过第 0 层归一化后, $\|z_1\| = \|T_0(x)\| = \|N_0(x + h_0(x))\| \leq R_{norm}$ (第一步)。
- 对每个后续层 l , $\|z_{l+1}\| = \|T_l(z_l)\| = \|N_l(z_l + h_l(z_l))\| \leq R_{norm}$ 。

因此 $\|z_L\| \leq R_{norm}$, 无论深度 L 多大。再由假设 3 中 f_{top} 的 Lipschitz 性与参考点有界性,

$$\|f_\theta(x) - f_{top}(0)\| \leq L_{top}\|z_L\| \leq L_{top}R_{norm},$$

从而

$$\|f_\theta(x)\| \leq \|f_{top}(0)\| + L_{top}R_{norm} \leq B_0 + L_{top}R_{norm} \triangleq B_{top}.$$

也就是说, 模型输出始终落在一个统一有界的球内。这个结论保证了后续的损失比较始终发生在固定的输出区域上; 在第七步真正应用 Massart 引理时, 我们将直接对有界损失类 $\ell \circ \mathcal{H}$ 工作, 因此包络常数来自 B_ℓ , 而不是来自 B_{top} 。

注: 上面用了 $\|N_l(\cdot)\| \leq R_{norm}$ (第一步的结论), 这是归一化层的**输出范数上界**, 不是通过 Lipschitz 常数逐层累乘得到的。这就是归一化的关键作用——它在每一层"重置"表示范数, 阻止了指数增长。

然而, 在第五步分析参数扰动的传播时, 我们仍然需要第 l 层扰动经过后续各层的**放大倍数**。扰动 δz_l 经过第 $k > l$ 层时, 由第二步的 Lipschitz 性质放大 $c_k(1 + s_k)$ 倍 (归一化对扰动的 Lipschitz 放大不等于对范数的截断——前者控制差值, 后者控制绝对值)。这一放大链将出现在第五步的 Λ_l 定义中。

第四步：参数空间紧性。

每层残差支路 h_l 由参数 $W_l \in \mathbb{R}^{d_l}$ 参数化 (含权重矩阵和偏置), 约束为 $\|W_l\|_\sigma \leq s_l$, $\|W_l\|_F \leq b_l$ (条件 B)。定义参数空间:

$$\Theta = \{(W_0, \dots, W_{L-1}) : \|W_l\|_\sigma \leq s_l, \|W_l\|_F \leq b_l, \forall l\}$$

Θ 是 $\mathbb{R}^d$ ($d = \sum_l d_l$) 中的**有界闭集**, 因此是**紧集**。

第五步：整网对参数的 Lipschitz 性质 (Telescoping 论证)。

固定输入 x 。设 $\theta = (W_0, \dots, W_{L-1})$, $\theta' = (W'_0, \dots, W'_{L-1})$ 为两组参数。定义**混合参数向量** $\theta^{(l)}$ ($0 \leq l \leq L$), 其中前 l 层使用 θ' , 后 $L - l$ 层使用 θ :

$$\theta^{(l)} = (W'_0, \dots, W'_{l-1}, W_l, \dots, W_{L-1})$$

则 $\theta^{(0)} = \theta$, $\theta^{(L)} = \theta'$ 。由三角不等式:

$$\|f_\theta(x) - f_{\theta'}(x)\| \leq \sum_{l=0}^{L-1} \|f_{\theta^{(l)}}(x) - f_{\theta^{(l+1)}}(x)\|$$

现在控制每一项 $\|f_{\theta^{(l)}}(x) - f_{\theta^{(l+1)}}(x)\|$ 。这两个模型的**唯一区别**在于第 l 层参数 (前者 W_l , 后者 W'_l), 其余所有层完全一致。因此它们到达第 l 层的中间表示**完全相同**, 记为 z_l^{mix} 。

定义 $R_* \triangleq \max\{R, R_{norm}\}$ 。对 z_l^{mix} 的范数: 当 $l = 0$ 时 $z_0^{mix} = x$, $\|z_0^{mix}\| \leq R \leq R_*$; 当 $l \geq 1$ 时 z_l^{mix} 是前一层归一化的输出, $\|z_l^{mix}\| \leq R_{norm} \leq R_*$ 。因此对所有 l : $\|z_l^{mix}\| \leq R_*$ 。

第 l 层的**局部误差**: 由条件 (L2),

$$\|h_l(z_l^{mix}; W_l) - h_l(z_l^{mix}; W'_l)\| \leq L_l^{(p)} \|W_l - W'_l\|_F \cdot R_*$$

经归一化层 N_l (Lipschitz 常数 c_l) 后, 局部误差为 $\|\delta z_{l+1}\| \leq c_l \cdot L_l^{(p)} \cdot R_* \cdot \|W_l - W'_l\|_F$ 。

误差向后传播: $\theta^{(l)}$ 和 $\theta^{(l+1)}$ 在第 l 层之后的参数完全一致, 每层 Lipschitz 常数为 $c_k(1 + s_k)$ (第二步)。误差逐层放大, 最终经顶层映射 f_{top} 传到输出:

$$\|f_{\theta^{(l)}}(x) - f_{\theta^{(l+1)}}(x)\| \leq L_{top} \cdot c_l \cdot L_l^{(p)} \cdot R_* \cdot \prod_{k>l} c_k(1 + s_k) \cdot \|W_l - W'_l\|_F$$

Telescoping 求和: 令 $\Lambda_l = L_{top} \cdot L_l^{(p)} \cdot R_* \cdot c_l \cdot \prod_{k>l} c_k(1 + s_k)$, 代回:

$$\sup_{\|x\| \leq R} \|f_{\theta}(x) - f_{\theta'}(x)\| \leq \sum_{l=0}^{L-1} \Lambda_l \|W_l - W'_l\|_F \leq \Lambda_{\max} \sum_{l=0}^{L-1} \|W_l - W'_l\|_F$$

其中 $\Lambda_{\max} = \max_l \Lambda_l$ 。

为什么 Telescoping 是必要的: 若直接对每层独立分析扰动 (不引入混合参数), z_l 在两组参数下一般不同, 条件 (L2) 的右端 $\|z_l\|$ 无法统一控制。Telescoping 保证了在分析第 l 层差异时, 前 l 层的参数一致, z_l^{mix} 是同一个量, 从而 (L2) 严格适用。

第六步: 参数空间覆盖数。

Θ 中每层的参数约束为 $\|W_l\|_F \leq b_l$, 这是 $\mathbb{R}^{d_l}$ 中半径 b_l 的球。半径 b 的 d -维球的 ϵ -覆盖数满足:

$$\mathcal{N}(B^d(b), \epsilon) \leq \left(\frac{2b}{\epsilon} + 1\right)^d$$

由第五步, 要使**输出函数类**的覆盖精度为 ϵ (即 $\sup_x \|f_{\theta}(x) - f_{\theta'}(x)\| \leq \epsilon$), 只需 $\Lambda_{\max} \sum_l \|W_l - W'_l\|_F \leq \epsilon$, 即每层参数精度为 $\epsilon_l = \epsilon / (L \cdot \Lambda_{\max})$ 。第 l 层需要的覆盖球数为 $(2b_l L \Lambda_{\max} / \epsilon + 1)^{d_l}$ 。总覆盖数为各层之积:

$$\log \mathcal{N}(\mathcal{H}, \epsilon) \leq \sum_{l=0}^{L-1} d_l \log \left(\frac{2b_l L \Lambda_{\max}}{\epsilon} + 1 \right) \leq d \cdot \log \left(\frac{2\bar{b} L \Lambda_{\max}}{\epsilon} + 1 \right)$$

其中 $d = \sum_l d_l$, $\bar{b} = \max_l b_l$ 。关键: 这是一个**不依赖 M 的有限量**。

第七步: 从输出函数类覆盖数到损失类 Rademacher 复杂度。

令 $\mathcal{H}_{\epsilon_0/L_\ell} \subset \mathcal{H}$ 为输出函数类在一致范数下的一个 ϵ_0/L_ℓ -网。由于损失 ℓ 是 L_ℓ -Lipschitz 的, 对任意 θ, θ' 都有

$$\sup_{(x,y)} |\ell(f_{\theta}(x), y) - \ell(f_{\theta'}(x), y)| \leq L_\ell \sup_x \|f_{\theta}(x) - f_{\theta'}(x)\|.$$

因此, 由 $\mathcal{H}_{\epsilon_0/L_\ell}$ 诱导出的损失类 $(\ell \circ \mathcal{H})_{\epsilon_0}$ 是 $\ell \circ \mathcal{H}$ 的一个 ϵ_0 -网, 并且

$$\log \mathcal{N}(\ell \circ \mathcal{H}, \epsilon_0) \leq \log \mathcal{N}(\mathcal{H}, \epsilon_0/L_\ell) \leq d \cdot \log \left(\frac{2\bar{b} L L_\ell \Lambda_{\max}}{\epsilon_0} + 1 \right).$$

再由 Massart 引理 (有限假设类的 Rademacher 界), 对有限损失类网 $(\ell \circ \mathcal{H})_{\epsilon_0}$ 有

$$\hat{\mathfrak{R}}_S((\ell \circ \mathcal{H})_{\epsilon_0}) \leq B_\ell \sqrt{\frac{2 \log |(\ell \circ \mathcal{H})_{\epsilon_0}|}{M}},$$

因为损失始终满足 $0 \leq \ell \leq B_\ell$ 。同时, 由近似误差控制,

$$\hat{\mathfrak{R}}_S(\ell \circ \mathcal{H}) \leq \hat{\mathfrak{R}}_S((\ell \circ \mathcal{H})_{\epsilon_0}) + \epsilon_0.$$

代入覆盖数估计，得到

$$\hat{\mathfrak{R}}_S(\ell \circ \mathcal{H}) \leq B_\ell \sqrt{\frac{2d \log(2\bar{b}LL_\ell\Lambda_{\max}/\epsilon_0 + 1)}{M}} + \epsilon_0.$$

取 $\epsilon_0 = 1/\sqrt{M}$:

$$\hat{\mathfrak{R}}_S(\ell \circ \mathcal{H}) \leq B_\ell \sqrt{\frac{2d \log(2\bar{b}LL_\ell\Lambda_{\max}\sqrt{M} + 1)}{M}} + \frac{1}{\sqrt{M}} = \mathcal{O}\left(B_\ell \sqrt{\frac{d \log M}{M}}\right) \quad (\square)$$

核心结论：在带有归一化的残差网络中，只要各层的谱范数和 Frobenius 范数被统一控制，且顶层映射 f_{top} 满足 Lipschitz 条件，则损失类的经验 Rademacher 复杂度按 $\tilde{O}(1/\sqrt{M})$ 衰减。证明仅需三个要素：(1) 归一化截断每层输入范数（第一步），(2) 逐层 Lipschitz 常数控制整网对输入和参数的敏感性（第二—五步），(3) 参数空间紧性提供有限覆盖数，再经损失的 Lipschitz 性与 Massart 引理转化为损失类的复杂度界（第六—七步）。

此引理对 $\mathcal{H}_{old}$ 和 $\mathcal{H}_{new}$ 均成立——只要各层满足谱/Frobenius 范数约束、归一化条件以及顶层 Lipschitz 条件。引理 3 在主链路中均被使用两次。为简洁起见，下文记 $\epsilon_M \triangleq \epsilon_{gen}^{norm}(\mathcal{H}_{new}, M, \delta)$ 、 $\epsilon_K \triangleq \epsilon_{gen}^{norm}(\mathcal{H}_{new}, K, \delta)$ （即引理 3 在大小为 M 或 K 的样本上的同一界）：

- **在定理 4A 中：**两次都对训练集应用，分别控制跳板模型 $\tilde{f}_{\eta_0}$ 与新模型 f_{new} 的训练-总体差 ($\mathcal{L}_{train} \leftrightarrow R$)，产生 $2\epsilon_{gen}^{norm} = 2\epsilon_M$ 。
- **在定理 4B 中：**一次对训练集、一次对独立测试集应用，分别得到 $|\mathcal{L}_{train} - R| \leq \epsilon_M$ 与 $|\mathcal{L}_{test} - R| \leq \epsilon_K$ ，再由三角不等式合成 $|\mathcal{L}_{train} - \mathcal{L}_{test}| \leq \epsilon_M + \epsilon_K$ ；总泛化代价系数为 $2(\epsilon_M + \epsilon_K)$ 。

在讨论（第 8.8 节）中给出了一个可选的改进：对跳板子空间使用更紧的引理 2，可将定理 4A 中的 $2\epsilon_{gen}^{norm}$ 改进为 $\epsilon_{gen}^{sp} + \epsilon_{gen}^{norm}$ 。

第六章 主定理：定性 Scaling Law

第七章给出测试集上的完整定量不等式（定理 4A 与定理 4B 两条平行路径）。本章的定理 3 是定理 4A 在 $K \rightarrow \infty$ （无限测试集）时的极限推论，给出总体风险上的定性结论。注意：定理 4B 在 $K \rightarrow \infty$ 的极限下退化为同一结论，因为 $\epsilon_K \rightarrow 0$ 使 $\epsilon_M + \epsilon_K \rightarrow \epsilon_M$ ，且在此极限下 $\mathcal{L}_{test} \rightarrow R$ ，4B 的不等式与 4A 在 $K \rightarrow \infty$ 后的形式重合。

定理 3（定性 Scaling Law） 在假设 1、2(a)、3 和 5 成立的前提下，若优化算法的输出 f_{new} 满足 $\mathcal{L}_{train}(f_{new}) \leq \mathcal{L}_{train}(\tilde{f}_{\eta_0})$ （跳板模型的训练损失），

则存在仅依赖 $\mathcal{D}$ 和当前模型的不确定性正量 $\Delta_R > 0$ ，使得以至少 $1 - \delta$ 的概率：

$$R(f_{new}) \leq R(f_{old}^*) - \Delta_R - \Delta_{ERM} + 2\epsilon_{gen}^{norm}$$

特别地，当 $\Delta_R + \Delta_{ERM} > 2\epsilon_{gen}^{norm}$ 时（充分大的 M 或正的 Δ_{ERM} 保证）， $R(f_{new}) < R(f_{old}^*)$ 。

证明（由定理 4A 退化）

当 $K \rightarrow \infty$ 时， $\delta_{test} \rightarrow 0$ ， $\mathcal{L}_{test} \rightarrow R$ ，Hoeffding 项 $\Delta_R/4$ 消失。定理 4A 的 (★) 式中 $\Delta_R/2$ 恢复为 Δ_R ：

$$R(f_{new}) \leq R(f_{old}^*) - \Delta_R - \Delta_{ERM} + 2\epsilon_{gen}^{norm}$$

当 M 充分大使 $2\epsilon_{gen}^{norm} < \Delta_R + \Delta_{ERM}$ 时， $R(f_{new}) < R(f_{old}^*)$ 。■

注：定理 3 不需要假设 4，因为 $K \rightarrow \infty$ 时宽度的概率角色消失。

第七章 测试集上的 Scaling Law（定理 4A 与定理 4B）

本章给出**主定理**——测试集上的 Scaling Law，包含两条平行的严格化路径：**定理 4A** (§7.2) 经由总体风险层面建立确定性正 margin Δ_R ，再通过泛化界和 Hoeffding 不等式转移到有限测试集；**定理 4B** (§7.3) 则**完全在训练集/测试集层面工作**，不引入任何 Hoeffding，并允许 $\Delta_R^{test} = 0$ 。两条路径在主结论上互相支撑：4A 给出更紧的泛化代价系数 $2\epsilon_M$ （但要求 $\Delta_R > 0$ ），4B 给出更宽松的退化容忍（但泛化代价系数为 $2(\epsilon_M + \epsilon_K)$ ）。定理 3（第六章）是 4A 在 $K \rightarrow \infty$ 时的定性推论。

7.1 定理 4A 陈述

定理 4A（测试集 Scaling Law——主定理） 在假设 1、2(a)、3 和 5 成立的前提下，若优化算法满足 $\mathcal{L}_{train}(f_{new}) \leq \mathcal{L}_{train}(\tilde{f}_{\eta_0})$ （其中 $\tilde{f}_{\eta_0}$ 为下文构造的跳板模型），

则存在仅依赖 $\mathcal{D}$ 和当前模型的不确定性正量 $\eta_0 > 0$ 、 $\Delta_R > 0$ （由第一、二步构造），以及优化收益 $\Delta_{ERM} \geq 0$ ，使得以至少 $1 - \delta_{gen} - \delta_{test}$ 的概率：

$$\boxed{\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*) - \frac{\Delta_R}{2} - \Delta_{ERM} + 2\epsilon_{gen}^{norm}} \quad (\star)$$

其中 $\delta_{gen} = \delta_1 + \delta_2 \rightarrow 0$ ($M \rightarrow \infty$)， $\delta_{test} = 6 \exp\left(-\frac{K\Delta_R^2}{8B_\ell^2}\right) \rightarrow 0$ ($K \rightarrow \infty$)， $\epsilon_{gen}^{norm} \rightarrow 0$ ($M \rightarrow \infty$)。

特别地：

(a) **（不恶化）** 当 M, K 充分大使得 $2\epsilon_{gen}^{norm} \leq \Delta_R/2$ 时，无论 Δ_{ERM} 取何值，

$$\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*)$$

即加深**不会使模型变差**。

(b) **（严格改善）** 当进一步 $\Delta_R/2 + \Delta_{ERM} > 2\epsilon_{gen}^{norm}$ 时，

$$\mathcal{L}_{test}(f_{new}) < \mathcal{L}_{test}(f_{old}^*)$$

即加深**严格改善**模型。在实际训练中，此条件通常由 $\Delta_{ERM} > 0$ （优化算法在新假设空间上取得正收益）保证。

解读：定理的核心结论是 $(\star)$ 式——一个精确的不等式，而非简单的“严格更好”。随着 $M, K \rightarrow \infty$ ，泛化代价消失， $(\star)$ 退化为 $\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*) - \Delta_R/2 - \Delta_{ERM}$ 。加深是否严格改善取决于 $\Delta_R + \Delta_{ERM}$ 是否为正。当可用的一阶下降 margin Δ_R 与优化收益 Δ_{ERM} 同时趋于零（逼近最深模型）时，改善消失但不恶化——这就是 scaling 的天花板。

7.2 定理 4A 证明

第一步：固定跳板路径。

由假设 2(a)，存在参数方向 v 使得

$$a \triangleq \mathbb{E} \left[\nabla_{x^{(l)}} \ell(f_{top}(x^{(l)}), y)^T \cdot \frac{\partial h_{\theta}(x^{(l)})}{\partial \theta} \Big|_{\theta=0} \cdot v \right] \neq 0$$

取 v 或 $-v$ 使 $a < 0$ 。定义跳板路径 $\theta(\eta) = \eta v$ ($\eta \geq 0$)，跳板模型为：

$$\tilde{f}_{\eta}(x) = f_{top}(x^{(l)} + h_{\eta v}(x^{(l)}))$$

关键性质：路径 v 由当前模型与残差块在零点处的一阶结构确定；一旦旧模型 f_{old}^* 被固定， v 、 η_0 与后续的 Δ_R 都是确定性对象。构造与定理 1 完全一致。

第二步：证明总体风险沿此路径严格下降——存在固定的 η_0 和确定性正 margin Δ_R 。

定义沿路径的总体风险：

$$G(\eta) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_{top}(x^{(l)} + h_{\eta v}(x^{(l)})), y)]$$

由假设 1 (C^1 正则性) 和链式法则：

$$G'(0) = \mathbb{E} \left[\nabla_{x^{(l)}} \ell(f_{top}(x^{(l)}), y)^T \cdot \frac{\partial h_{\theta}(x^{(l)})}{\partial \theta} \Big|_{\theta=0} \cdot v \right] = a < 0 \quad (\text{I})$$

由 $G'(0) < 0$ 和 G 的连续性，存在 $\eta_0 > 0$ 使得：

$$R(\tilde{f}_{\eta_0}) = G(\eta_0) < G(0) - \Delta_R = R(f_{old}^*) - \Delta_R$$

其中 $\Delta_R \triangleq G(0) - G(\eta_0) > 0$ 。

关键性质： η_0 和 Δ_R 仅依赖分布 $\mathcal{D}$ 与当前固定的旧模型，是**确定性正量**——不依赖测试集，也不依赖优化过程。跳板模型 $\tilde{f}_{\eta_0}$ 是一个固定函数。

含偏置项的特例：对例 1（输出端无归一化），取 v 为偏置方向 $-\bar{\mu}$ ， $\frac{\partial h}{\partial b_2} \Big|_{\theta=0} = I$ ，得 $a = -\|\bar{\mu}\|^2$ ， $G'(0) = -\|\bar{\mu}\|^2 < 0$ 。

第三步：从总体风险转移到测试集（Hoeffding 不等式）。

$\tilde{f}_{\eta_0}$ 和 f_{old}^* 均为固定函数（不依赖训练集和测试集）。对每个固定函数 f ，由 Hoeffding 不等式 ($\ell \in [0, B_{\ell}]$ ，测试集 K 个 i.i.d. 样本)：

$$P(|\mathcal{L}_{test}(f) - R(f)| > t) \leq 2 \exp\left(-\frac{2Kt^2}{B_{\ell}^2}\right)$$

对 $f = f_{old}^*$ 和 $f = \tilde{f}_{\eta_0}$ 分别应用，取 $t = \Delta_R/4$ ，由 union bound：

$$P(|\mathcal{L}_{test}(f_{old}^*) - R(f_{old}^*)| > \Delta_R/4 \text{ 或 } |\mathcal{L}_{test}(\tilde{f}_{\eta_0}) - R(\tilde{f}_{\eta_0})| > \Delta_R/4) \leq \delta_{test}$$

其中 $\delta_{test} = 4 \exp\left(-\frac{K\Delta_R^2}{8B_{\ell}^2}\right)$ 。在补事件上（概率 $\geq 1 - \delta_{test}$ ）：

$$\mathcal{L}_{test}(\tilde{f}_{\eta_0}) - \mathcal{L}_{test}(f_{old}^*) \leq [R(\tilde{f}_{\eta_0}) - R(f_{old}^*)] + 2 \cdot \frac{\Delta_R}{4} = -\Delta_R + \frac{\Delta_R}{2} = -\frac{\Delta_R}{2}$$

即：

$$\mathcal{L}_{test}(\tilde{f}_{\eta_0}) \leq \mathcal{L}_{test}(f_{old}^*) - \frac{\Delta_R}{2} \quad (\text{II})$$

注：此步中 $\Delta_R/2$ 是一个确定性正 margin（仅依赖 $\mathcal{D}$ 和当前模型），不依赖训练集或测试集的具体实现。

第四步：从跳板模型到新模型（泛化界 + 优化）。

跳板模型 $\tilde{f}_{\eta_0} \in \mathcal{H}_{new}$, $f_{new} \in \mathcal{H}_{new}$ 。由引理 3（对 $\mathcal{H}_{new}$ 的范数泛化界），以概率 $\geq 1 - \delta_1$ ：

$$\mathcal{L}_{train}(\tilde{f}_{\eta_0}) \leq R(\tilde{f}_{\eta_0}) + \epsilon_{gen}^{norm}(M, \delta_1) \quad (\text{III})$$

由条件 (ii)（优化）：

$$\mathcal{L}_{train}(f_{new}) \leq \mathcal{L}_{train}(\tilde{f}_{\eta_0}) - \Delta_{ERM}, \quad \Delta_{ERM} \geq 0 \quad (\text{IV})$$

由引理 3（同一泛化界，对 f_{new} 适用），以概率 $\geq 1 - \delta_2$ ：

$$R(f_{new}) \leq \mathcal{L}_{train}(f_{new}) + \epsilon_{gen}^{norm}(M, \delta_2) \quad (\text{V})$$

再对 f_{new} （条件于训练集后为固定函数）应用 Hoeffding（取 $t = \Delta_R/4$ ）：

$$\mathcal{L}_{test}(f_{new}) \leq R(f_{new}) + \frac{\Delta_R}{4} \quad (\text{VI})$$

以概率 $\geq 1 - 2 \exp(-K \Delta_R^2 / (8B_\ell^2))$ 。与第三步对 f_{old}^* 和 $\tilde{f}_{\eta_0}$ 的 Hoeffding 合并（union bound over 三个函数），总 Hoeffding 失败概率为 $\delta_{test} = 6 \exp(-K \Delta_R^2 / (8B_\ell^2))$ 。

第五步：全链路闭合。

串联 (VI) $\rightarrow$ (V) $\rightarrow$ (IV) $\rightarrow$ (III)：

$$\mathcal{L}_{test}(f_{new}) \leq R(f_{new}) + \frac{\Delta_R}{4} \leq \mathcal{L}_{train}(f_{new}) + \epsilon_{gen}^{norm} + \frac{\Delta_R}{4}$$

$$\leq \mathcal{L}_{train}(\tilde{f}_{\eta_0}) - \Delta_{ERM} + \epsilon_{gen}^{norm} + \frac{\Delta_R}{4}$$

$$\leq R(\tilde{f}_{\eta_0}) + \epsilon_{gen}^{norm} - \Delta_{ERM} + \epsilon_{gen}^{norm} + \frac{\Delta_R}{4}$$

由第二步， $R(\tilde{f}_{\eta_0}) = R(f_{old}^*) - \Delta_R$ 。由 (II) 的推导过程中的 Hoeffding， $R(f_{old}^*) \leq \mathcal{L}_{test}(f_{old}^*) + \Delta_R/4$ 。代入：

$$\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*) + \frac{\Delta_R}{4} - \Delta_R + 2\epsilon_{gen}^{norm} - \Delta_{ERM} + \frac{\Delta_R}{4}$$

$$= \mathcal{L}_{test}(f_{old}^*) - \frac{\Delta_R}{2} - \Delta_{ERM} + 2\epsilon_{gen}^{norm}$$

这正是定理陈述中的 (★) 式。以概率 $\geq 1 - \delta_{test} - \delta_1 - \delta_2$ （其中 $\delta_{test} = 6 \exp(-K \Delta_R^2 / (8B_\ell^2))$ ）成立。

结论 (a)（不恶化）：当 $2\epsilon_{gen}^{norm} \leq \Delta_R/2$ 时，由 $\Delta_{ERM} \geq 0$ 立即得 $\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*)$ 。

结论 (b)（严格改善）：当 $\Delta_R/2 + \Delta_{ERM} > 2\epsilon_{gen}^{norm}$ 时，严格不等号成立。■

关于条件 (b) 的两种实现方式：

(充分条件 A) M 充分大使 $2\epsilon_{gen}^{norm} < \Delta_R/2$ ——仅靠 Δ_R 即可，不需要 Δ_{ERM} 。但 Δ_R 来自一阶泰勒，可以很小，对 M 的要求可能很高。

(充分条件 B) $\Delta_{ERM} > 2\epsilon_{gen}^{norm}$ ——仅靠优化收益即可。在实际训练中更自然： Δ_{ERM} 是优化算法在整个 $\mathcal{H}_{new}$ 上搜索的收益，通常远大于一阶微扰的 Δ_R 。

证明链路总结：

$$R(f_{old}^*) \xrightarrow[\text{第二步: } C^1]{-\Delta_R} R(\tilde{f}_{\eta_0}) \xrightarrow[\text{第四步(III): 引理3}]{+\epsilon_{gen}^{norm}} \mathcal{L}_{train}(\tilde{f}_{\eta_0}) \xrightarrow[\text{第四步(IV): 优化}]{-\Delta_{ERM}} \mathcal{L}_{train}(f_{new}) \xrightarrow[\text{第四步(V): 引理3}]{+\epsilon_{gen}^{norm}} R(f_{new})$$

两端再经 Hoeffding ($\pm \Delta_R/4$) 连接到 $\mathcal{L}_{test}$ 。 Δ_R 保证方向， Δ_{ERM} 提供 margin，泛化界随 M 消失。引理 3 在链路中使用了两次（分别控制 $\tilde{f}_{\eta_0}$ 和 f_{new} 的泛化），产生 $2\epsilon_{gen}^{norm}$ 。

7.3 定理 4B：不依赖 Hoeffding 的测试集 Scaling Law

定理 4A 通过总体风险 R 作媒介，再用 Hoeffding 把 R 与 $\mathcal{L}_{test}$ 连接。这条路径的代价是：(1) 三处 Hoeffding 引入 $\Delta_R/4$ 的松弛，使最终 margin 从 Δ_R 退化为 $\Delta_R/2$ ；(2) Hoeffding 失败概率 $6 \exp(-K \Delta_R^2 / (8B_\ell^2))$ 在 $\Delta_R \rightarrow 0$ 时急剧恶化；(3) 论证依赖 $\Delta_R > 0$ 。

定理 4B 给出一条**完全绕过 R 与 Hoeffding** 的平行严格化：直接用引理 3 的两侧泛化界，通过三角不等式得到

$|\mathcal{L}_{train}(f) - \mathcal{L}_{test}(f)| \leq \epsilon_M + \epsilon_K$ （对 $\mathcal{H}_{new}$ 中所有 f 一致成立），然后在训练集/测试集层面闭合。这条路径**允许** $\Delta_R^{test} = 0$ （退化跳板情形），代价是泛化代价系数从 $2\epsilon_M$ 变为 $2(\epsilon_M + \epsilon_K)$ 。

定理陈述

定理 4B（不依赖 Hoeffding 的测试集 Scaling Law） 在假设 1、2(a)、3 和 5 成立的前提下，设 $\tilde{f} \in \mathcal{H}_{new}$ 为按假设 2(a) 给出的参数方向 v 构造的跳板模型 $\tilde{f}_{\eta_0}$ ，**允许** $\eta_0 = 0$ （此时 $\tilde{f} = f_{old}^*$ ，记为退化跳板情形）。结论 (a)（不恶化）不需要任何额外假设；结论 (b)（严格改善）的非退化版本另需假设 4 以及定理 2 的条件 (i)、(ii)。设优化算法的输出 $f_{new} \in \mathcal{H}_{new}$ 满足

$$\mathcal{L}_{train}(f_{new}) \leq \mathcal{L}_{train}(\tilde{f}) - \Delta_{ERM}, \quad \Delta_{ERM} \geq 0.$$

记 $\epsilon_M \triangleq \epsilon_{gen}^{norm}(\mathcal{H}_{new}, M, \delta)$ 、 $\epsilon_K \triangleq \epsilon_{gen}^{norm}(\mathcal{H}_{new}, K, \delta)$ ，并定义测试集层面的跳板 margin

$$\Delta_R^{test} \triangleq \mathcal{L}_{test}(f_{old}^*) - \mathcal{L}_{test}(\tilde{f}).$$

则以概率 $\geq 1 - 2\delta$ （退化情形）或 $\geq 1 - 3\delta$ （非退化情形）：

$$\boxed{\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*) - \Delta_R^{test} - \Delta_{ERM} + 2(\epsilon_M + \epsilon_K)} \quad (\star\star)$$

特别地：

(a)（退化版不恶化） 取 $\tilde{f} = f_{old}^*$ ，则 $\Delta_R^{test} = 0$ 。当 $\Delta_{ERM} \geq 2(\epsilon_M + \epsilon_K)$ 时，

$$\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*),$$

即加深**依概率不恶化**测试损失。这一结论**不要求** $\Delta_R > 0$ ，对最深模型附近 ($\bar{\mu} \rightarrow 0$) 仍然成立。

(b) (非退化版严格改善) 非退化情形下，由定理 2 提供 $\Delta_R^{test} \geq 0$ 的概率保证（失败概率 δ_3 ，已计入总失败概率）。当 $\Delta_R^{test} + \Delta_{ERM} > 2(\epsilon_M + \epsilon_K)$ 时，

$$\mathcal{L}_{test}(f_{new}) < \mathcal{L}_{test}(f_{old}^*).$$

证明

第一步：通过引理 3 直接控制 $|\mathcal{L}_{train} - \mathcal{L}_{test}|$ 。

引理 3 的证明只用到样本是从 $\mathcal{D}$ 抽出的 i.i.d. 这一性质——它对训练集和测试集同等成立（测试集的 K 个样本独立于训练集，本身就是大小为 K 的 i.i.d. 样本）。因此：

- 在训练集上，以概率 $\geq 1 - \delta$ ，对所有 $f \in \mathcal{H}_{new}$ ：

$$|\mathcal{L}_{train}(f) - R(f)| \leq \epsilon_M$$

- 在测试集上（独立抽样），以概率 $\geq 1 - \delta$ ，对所有 $f \in \mathcal{H}_{new}$ ：

$$|\mathcal{L}_{test}(f) - R(f)| \leq \epsilon_K$$

由 union bound，两事件交集发生概率 $\geq 1 - 2\delta$ 。在交集上，由三角不等式，对所有 $f \in \mathcal{H}_{new}$ ：

$$|\mathcal{L}_{train}(f) - \mathcal{L}_{test}(f)| \leq |\mathcal{L}_{train}(f) - R(f)| + |R(f) - \mathcal{L}_{test}(f)| \leq \epsilon_M + \epsilon_K \triangleq \epsilon_{TT} \quad (\text{I})$$

关键： $R(f)$ 在此只是三角不等式中的**形式锚点**，从未被显式估计或单独计算。整条证明链不再需要计算总体风险。

第二步：跳板模型从测试集到训练集。

由 (I) 应用于 $f = \tilde{f} \in \mathcal{H}_{new}$ ：

$$\mathcal{L}_{train}(\tilde{f}) \leq \mathcal{L}_{test}(\tilde{f}) + \epsilon_{TT} \quad (\text{II})$$

第三步：优化条件。

由条件 (ii)：

$$\mathcal{L}_{train}(f_{new}) \leq \mathcal{L}_{train}(\tilde{f}) - \Delta_{ERM} \quad (\text{III})$$

第四步：新模型从训练集回到测试集。

由 (I) 应用于 $f = f_{new} \in \mathcal{H}_{new}$ ：

$$\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{train}(f_{new}) + \epsilon_{TT} \quad (\text{IV})$$

第五步：跳板与旧模型在测试集上的关系。

由 Δ_R^{test} 的定义，

$$\mathcal{L}_{test}(\tilde{f}) = \mathcal{L}_{test}(f_{old}^*) - \Delta_R^{test} \quad (\text{V})$$

这是一个等式，对 Δ_R^{test} 的正负不作要求。两种情形：

- 退化情形** ($\eta_0 = 0, \tilde{f} = f_{old}^*$)： $\Delta_R^{test} = 0$ ，(V) 是平凡等式，**定理 2 不被使用**，总失败概率为 2δ 。
- 非退化情形** ($\eta_0 > 0$)：附加假设 4 与定理 2 的条件 (i) ($\bar{\mu} \neq 0$)、条件 (ii) ($M \geq M_1$)。定理 2 给出在偏置型/常向量方向特例下， $\eta \mapsto \mathcal{L}_{test}(\tilde{f}_\eta)$ 在 $\eta = 0$ 处的方向导数为 $-g^T \mu$ （其中 μ 由训练集确定， g 由独立测试集确定），由

$\mu^T g > 0$ (概率 $\geq 1 - 9C_\Sigma \tau^2 / (K \|\bar{\mu}\|^2)$) 得方向导数 < 0 。要使这一概率界 $\leq \delta$ ，等价于 $K \geq 9C_\Sigma \tau^2 / (\delta \|\bar{\mu}\|^2)$ ；将此条件下的失败概率记为 $\delta_3 \leq \delta$ 。如 §7.7 所述，从此方向信息提取使 $\Delta_R^{test} > 0$ 的有限 η_0 需要额外的局部 Lipschitz 控制；本定理对这一选择**不作硬性要求**——只要选到的 η_0 满足 $\Delta_R^{test} \geq 0$ 即可，否则回退为 $\eta_0 = 0$ 。非退化情形总失败概率为 $2\delta + \delta_3 \leq 3\delta$ 。

第六步：链路串联。

由 (IV) $\rightarrow$ (III) $\rightarrow$ (II) $\rightarrow$ (V)：

$$\begin{aligned} \mathcal{L}_{test}(f_{new}) &\stackrel{(IV)}{\leq} \mathcal{L}_{train}(f_{new}) + \epsilon_{TT} \\ &\stackrel{(III)}{\leq} \mathcal{L}_{train}(\tilde{f}) - \Delta_{ERM} + \epsilon_{TT} \\ &\stackrel{(II)}{\leq} (\mathcal{L}_{test}(\tilde{f}) + \epsilon_{TT}) - \Delta_{ERM} + \epsilon_{TT} = \mathcal{L}_{test}(\tilde{f}) - \Delta_{ERM} + 2\epsilon_{TT} \\ &\stackrel{(V)}{=} \mathcal{L}_{test}(f_{old}^*) - \Delta_R^{test} - \Delta_{ERM} + 2\epsilon_{TT}. \end{aligned}$$

代入 $\epsilon_{TT} = \epsilon_M + \epsilon_K$ 即得 (★★)。■

4A 与 4B 的对照

项目	定理 4A	定理 4B
中间媒介	总体风险 $R(f)$	直接 $\mathcal{L}_{train} \leftrightarrow \mathcal{L}_{test}$
Hoeffding 使用	用于 $f_{old}^*, \tilde{f}, f_{new}$ 三个固定函数	完全不用
是否需要 $\Delta_R > 0$	是（提供 $\Delta_R/2$ margin）	否（允许退化为 0）
引理 3 使用次数	2 次（仅对训练集）	2 次（训练 + 测试各一次）
泛化代价系数	$2\epsilon_M$	$2(\epsilon_M + \epsilon_K)$
定理 2 的角色	不使用	非退化情形下使用，退化情形下不使用
严格改善条件	$\Delta_R/2 + \Delta_{ERM} > 2\epsilon_M$	$\Delta_R^{test} + \Delta_{ERM} > 2(\epsilon_M + \epsilon_K)$
不恶化条件	同上	$\Delta_{ERM} \geq 2(\epsilon_M + \epsilon_K)$ （退化情形）

两条路径的互补性：

- 4A 的优势**：泛化代价系数 $2\epsilon_M$ 比 4B 的 $2(\epsilon_M + \epsilon_K)$ 紧（当 $K \ll M$ 时差距明显）。在数据充足（ Δ_R 不太小、 M 远大于 K ）的常规情形下，4A 给出更紧的不等式。
- 4B 的优势**：不依赖 $\Delta_R > 0$ ，**对最深模型附近退化情形天然鲁棒**。定理 4A 在 $\Delta_R \rightarrow 0$ 时 Hoeffding 失败概率 $6 \exp(-K \Delta_R^2 / (8B_\ell^2)) \rightarrow 1$ （指数项指数趋零），结论实质失效；定理 4B 此时仍然给出 $\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*) + 2(\epsilon_M + \epsilon_K) - \Delta_{ERM}$ ，只要 Δ_{ERM} 能压制泛化代价就成立。
- 互证关系**：两条路径不互相依赖。若两者同时成立（典型情形），它们彼此独立地证明了同一主结论，构成稳健的双重严格化；若 4A 因 Δ_R 太小而失效，4B 仍单独支撑结论。

证明链路总结（4B）：

$$\mathcal{L}_{test}(f_{old}^*) \xrightarrow[(V)]{-\Delta_R^{test}} \mathcal{L}_{test}(\tilde{f}) \xrightarrow[(II): \text{引理3}]{+\epsilon_{TT}} \mathcal{L}_{train}(\tilde{f}) \xrightarrow[(III): \text{优化}]{-\Delta_{ERM}} \mathcal{L}_{train}(f_{new}) \xrightarrow[(IV): \text{引理3}]{+\epsilon_{TT}} \mathcal{L}_{test}(f_{new})$$

五个量全部是可观测的训练/测试损失，无 R 、无 Hoeffding。引理 3 在 (II) 和 (IV) 中各使用一次，分别对应“训练泛化”和“测试泛化”两个方向，产生 $2\epsilon_{TT} = 2(\epsilon_M + \epsilon_K)$ 。

7.4 Δ_R 与 Δ_{ERM} 的角色分工

由 (★)，改善的净 margin 为 $\Delta_R/2 + \Delta_{ERM} - 2\epsilon_{gen}^{norm}$ 。理解各项的实际量级有助于理解 scaling 的机制。

Δ_R 的量级： Δ_R 来自一阶泰勒下降，步长 η_0 受 G 的曲率约束。在仅有 C^1 条件下， Δ_R 只保证 > 0 ，可以任意小。即使在有界曲率（假设 G' ）下， $\Delta_R = \Theta(\|\bar{\mu}\|^4/Q)$ ——当 $\|\bar{\mu}\| \rightarrow 0$ 时， Δ_R 以四次方速度趋于零。因此 Δ_R 很难单独承担压制泛化代价的任务。

Δ_{ERM} 的量级： $\Delta_{ERM} = \mathcal{L}_{train}(\tilde{f}_{\eta_0}) - \mathcal{L}_{train}(f_{new})$ 是优化算法在 $\mathcal{H}_{new}$ 中自由搜索的全部收益。跳板模型 $\tilde{f}_{\eta_0}$ 只是新假设空间中的一个特殊点（沿一阶方向的常数扰动），而 f_{new} 是优化算法充分利用新假设空间表达能力后的输出。在实际训练中， Δ_{ERM} 包含了数据依赖的非线性改善，通常远大于 Δ_R 。

实际 scaling 的核心机制：

$$\underbrace{\Delta_R/2}_{\text{微小, 保证方向}} + \underbrace{\Delta_{ERM}}_{\text{主力 margin}} > \underbrace{2\epsilon_{gen}^{norm}}_{\text{随 } M \text{ 衰减}}$$

Δ_R 的角色是**存在性保证**——它证明新假设空间严格优于旧假设空间 ($R(\tilde{f}_{\eta_0}) < R(f_{old}^*)$)，为优化算法提供了“至少存在一个更优解”的保证。 Δ_{ERM} 的角色是**实际 margin 提供者**——优化算法在训练集上的收益远超一阶方向的微小改进。

7.5 深度天花板的机制

(★) 式自然解释了深度 scaling 的天花板现象。

情况 1 ($\bar{\mu} \neq 0$ 且 $\Delta_{ERM} > 0$ ，正常 scaling)： $\Delta_R > 0$ 保证方向正确， Δ_{ERM} 大到足以压制泛化代价。加深有效。

情况 2 ($\bar{\mu} \rightarrow 0$ ，逼近天花板)： $\Delta_R \rightarrow 0$ ，同时因为新层的参数梯度也趋于零（推论 2），优化算法在新层上难以取得收益， $\Delta_{ERM} \rightarrow 0$ 。此时即使 M, K 很大消除了 ϵ_{gen} 和 δ_{test} ，(★) 退化为：

$$\mathcal{L}_{test}(f_{new}) \approx \mathcal{L}_{test}(f_{old}^*)$$

加深不再产生改善——但也不恶化（因为泛化代价被大数据压制）。

情况 3 ($\bar{\mu} = 0$ 且 $\Delta_{ERM} = 0$ ，性能下降)：新层完全无用 ($\Delta_R = 0$, $\Delta_{ERM} = 0$)，但新假设空间 $\mathcal{H}_{new}$ 比 $\mathcal{H}_{old}$ 更大，泛化代价 $\epsilon_{gen}^{norm}(\mathcal{H}_{new}) > \epsilon_{gen}^{norm}(\mathcal{H}_{old})$ 。此时 (★) 给出：

$$\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*) + 2\epsilon_{gen}^{norm}$$

如果泛化代价不可忽略 (M 不够大)，**加深反而使性能下降**。这与实际观察一致——过深的网络在数据量不足时泛化变差。

总结：深度天花板不是简单地由某个单独的平均梯度条件决定，而是因为 Δ_R 和 Δ_{ERM} 同时趋于零，净 margin 无法压制泛化代价的增量。

7.6 宽度的角色：概率可靠性的不可替代条件

由 (★)，改善条件为 $\Delta_R/2 + \Delta_{ERM} > 2\epsilon_{gen}^{norm}$ 。在条件 B (Δ_{ERM} 承担主力 margin) 的视角下，宽度的角色更加清晰。

宽度如何影响 Δ_{ERM} ：优化算法在 $\mathcal{H}_{new}$ 上的搜索收益 Δ_{ERM} 取决于新假设空间的表达能力。更宽的网络（ N 更大）使每一层残差块的参数空间更大，优化算法有更多方向可以改善训练损失， Δ_{ERM} 更大。

宽度如何影响 Δ_R ：在方向导数版定理 1 中， Δ_R 的严格来源是"存在某个 v 使 $G'(0) < 0$ "。这一点本身并不要求 $G'(0)$ 必须写成 $-\|\bar{\mu}\|^2$ 。不过，在一个重要的结构化特例——输出端无归一化且含偏置、从而 $\frac{\partial h}{\partial b_2}|_0 = I$ ——有

$$G'(0) = -\|\bar{\mu}\|^2.$$

若再结合交换性条件 (§8.3 评注) 得到 $\|\bar{\mu}\|^2 = N\bar{\mu}_1^2$ ，则增加 N 会线性放大 $|G'(0)|$ ，从而放大由跳板路径产生的 Δ_R 。因此，本节关于"宽度放大 Δ_R "的结论应理解为一个**结构化充分机制**：它对偏置型/常向量方向子类是严格的，对一般方向导数版定理 1 则提供启发而非自动结论。

宽度如何影响泛化代价：在方案 B 的引理 3 中， ϵ_{gen}^{norm} 由损失类覆盖数控制，其主要宽度依赖体现在参数维度 d 以及常数 $\Lambda_{\max}$ 上：随着 N 增加， d 通常增大，且 $R_{norm} = O(\sqrt{N})$ 可能通过 $\Lambda_{\max}$ 进入对数项。因此，增大 N 会提高泛化代价的结构常数，但 ϵ_{gen}^{norm} 整体仍按 $\tilde{O}(1/\sqrt{M})$ 衰减——宽度改变的是覆盖数常数与对数项，而不是衰减率。对于足够大的 M ， Δ_{ERM} 的增长仍可能超过泛化代价的增长。

宽度是唯一能同时放大优化侧 margin，并在结构化特例中放大方向导数侧 margin 的架构手段。深度提供新的下降方向，宽度放大这些方向被优化和被观测到的强度，数据决定泛化代价与 Hoeffding 误差能否被压制。

三个维度的角色：

维度	对 Δ_R 的效果	对 Δ_{ERM} 的效果	对泛化代价的效果
深度 $L \uparrow$	提供新的可用下降方向	间接（新空间更大）	ϵ_{gen}^{norm} 增加（更多层）
宽度 $N \uparrow$	在偏置型特例中放大 \$	$G'(0)$	\$，一般情形下增强可观测性
数据 $M, K \uparrow$	不影响	不影响	$\epsilon_{gen} \rightarrow 0, \delta_{test} \rightarrow 0$

深度决定改善**能否存在**（是否存在负方向导数），宽度决定改善的**实际幅度与可靠性**，数据决定泛化代价**能否被压制**。

7.7 关于定理 2 在主链路中的地位

原版证明试图将定理 2 ($P(\mu^T g > 0) \geq 1 - O(1/(KN))$) 作为主链路的第一步：由方向信息直接推出测试集下降。这条路径存在两个未封闭的间隙：

间隙 1： $\mu^T g > 0$ 是**方向信息**——它说明测试集损失在 $\eta = 0$ 处的导数为负，但不直接给出存在某个**固定的** $\eta_0 > 0$ 使损失严格下降。要从方向信息推出有限步长下降，需要 $\eta \mapsto \mathcal{L}_{test}(\tilde{f}_\eta)$ 在某个 η 区间上的一致连续性/曲率控制。由于 $\mathcal{L}_{test}$ 是 K 个样本的有限平均，这种控制是可能的（例如通过 C^1 正则性 + Lipschitz 性质），但需要显式论证。

间隙 2：即使封闭间隙 1，得到的 η_0 和测试集改善量 Δ_R^{test} 可能依赖于测试集的具体实现。在不同的测试集实现上， $\mu^T g$ 的值不同， η_0 也不同。要得到**统一的** margin（使后续泛化代价可以被压制），需要对 Δ_R^{test} 的正下界做额外论证。

两条主路径如何处理这些间隙：

- 定理 4A**：通过在**总体风险**层面工作完全回避了这两个间隙。 Δ_R 是总体风险的确定性差值， η_0 不依赖测试集，Hoeffding 提供了统一的概率控制。定理 2 完全不进入 4A 的证明。
- 定理 4B**：在退化情形（ $\eta_0 = 0$ ）下也完全回避了这两个间隙——根本不需要从方向信息提取下降步长。在非退化情形下，定理 2 提供 $\mu^T g > 0$ 的概率保证，间隙 1 的封闭由"任意满足 $\Delta_R^{test} \geq 0$ 的 η_0 都可接受"绕过（包括最弱的选择

$\eta_0 = 0$ ，此时 $\Delta_R^{test} = 0$ 是平凡满足的)。也就是说，**4B 对 η_0 的选择只要求 $\Delta_R^{test} \geq 0$ ，而不要求 $\Delta_R^{test} > 0$** ——间隙 1 与间隙 2 都被这一弱化吸收。这正是 4B 比 4A 更鲁棒的根源。

定理 2 在当前框架中的剩余价值在于：(1) 它提供了宽度影响可观测性的**直观解释**（去相关性使梯度信号不互相抵消）；(2) 在 $\|\bar{\mu}\| \rightarrow 0$ （逼近最深模型）时，它量化了"改善越来越难被观测到"的精确速率；(3) 它在 4B 的非退化情形下作为 $\Delta_R^{test} \geq 0$ 的概率支撑出现。这些洞察是第 7.6 节宽度分析的概念基础。

7.8 深度-宽度耦合的必要性

随着模型逐步加深（ L 增大），模型逼近最深模型，可用的一阶下降 margin Δ_R 往往趋于零。**对定理 4A 而言**，两个"充分大"条件同时恶化：

- Hoeffding 误差 $\delta_{test} = 6 \exp(-K\Delta_R^2/(8B_\ell^2))$ 增大（所需 K 增大）。
- 泛化代价压制条件 $2\epsilon_{gen}^{norm} < \Delta_R/2$ 越来越难满足（所需 M 增大）。

对定理 4B 而言，第一条恶化完全不发生（无 Hoeffding），第二条恶化退化为对 Δ_{ERM} 的需求——即 Δ_{ERM} 必须能压制 $2(\epsilon_M + \epsilon_K)$ ，其中 Δ_R^{test} 在最坏情形下取零。两条路径都将"加深时维持改善"的负担转移到了**宽度／优化收益／数据规模**这三个仍然可控的维度上。

由第 7.6 节的结构化分析，在偏置型/常向量方向子类中，增加宽度 N 能通过放大 $\|\bar{\mu}\|^2 = N\bar{\mu}_1^2$ 来增大 $|G'(0)|$ 和 Δ_R ；在更一般的方向导数版框架中，宽度至少能通过增大优化收益 Δ_{ERM} 、并提升改善被可靠观测到的强度来缓解上述两个条件。固定 K 后，宽度 N 往往必须随深度 L 增长以维持可靠性——这就产生了**深度-宽度耦合** $L = u(N)$ 。

耦合函数 u 的具体形式取决于 Δ_R 与 Δ_{ERM} 如何同时依赖 L 和 N 。在偏置型特例中，这种依赖可进一步写成 $\|\bar{\mu}\|^2$ 对 L 与 N 的联合依赖；第九章将引入假设 G 来刻画这一关系，并推导出 P 的 scaling law。

第八章 讨论

8.1 关于假设的结构

全文假设集中在第二章，按使用范围分为三组：

- **假设 1 + 假设 2(a)** (C^1 正则性、零点一阶可下降性)：定理 1（存在性）的全部所需。
- **假设 1、2(a)、3 + 假设 5**：定理 3、定理 4A 与定理 4B 的全部所需。假设 3（Lipschitz）和假设 5（ L_1, L_2, N, B ）通过引理 3（泛化控制）进入。定理 4B 比 4A 进一步弱化了对 $\Delta_R > 0$ 的依赖——其退化版本（ $\eta_0 = 0$ ）只需 Δ_{ERM} 即可压制泛化代价。
- **假设 2(b)**（复杂度包络）：仅在第 8.8 节的引理 2 中作为可选改进使用，不进入主链路。
- **假设 4**（梯度协方差谱范数有界）：仅在定理 2（梯度方向对齐）中使用，不进入定理 4A 的主链路；在定理 4B 的非退化情形下作为 $\Delta_R^{test} \geq 0$ 的概率支撑出现，但 4B 的退化情形完全不依赖它。可直接作为公理接受，也可由归一化层的置换等变性 + 高维去相关从架构层面 justify (§8.3 评注)。

假设 5 中的条件 (N) 可通过第 8.9 节的两条路径弱化或消除。

8.2 定理体系的层次结构

定理 4A（总体风险路径）：**(★)** 式 $\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*) - \Delta_R/2 - \Delta_{ERM} + 2\epsilon_{gen}^{norm}$ ，概率 $\geq 1 - \delta_{test} - \delta_{gen}$ 。
证明链路经由总体风险 R ：由假设 2(a) 取参数方向 v 使真实方向导数 $G'(0) < 0 \rightarrow$ 存在 η_0 使 $\Delta_R > 0 \rightarrow$ 引理 3 控制

泛化（两次）→ Hoeffding 转移到测试集。优势：泛化代价系数为 $2\epsilon_M$ ，紧。

定理 4B（训练-测试直接路径）：(★★) 式 $\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*) - \Delta_R^{test} - \Delta_{ERM} + 2(\epsilon_M + \epsilon_K)$ ，概率 $\geq 1 - 3\delta$ （非退化）或 $\geq 1 - 2\delta$ （退化）。证明完全在训练集/测试集层面工作，引理 3 同时对训练集和独立测试集应用，由三角不等式得 $|\mathcal{L}_{train} - \mathcal{L}_{test}| \leq \epsilon_M + \epsilon_K$ 一致界。**允许** $\Delta_R^{test} = 0$ （退化跳板情形），对最深模型附近天然鲁棒。代价：泛化代价系数变为 $2(\epsilon_M + \epsilon_K)$ ，对测试集大小要求更高。

两条路径的关系：4A 和 4B 互不依赖、彼此独立闭合同一主结论。在常规情形（ Δ_R 不太小、 $M \gg K$ ）下 4A 更紧；在退化情形（ $\Delta_R \rightarrow 0$ ）下 4A 因 Hoeffding 失败概率 $6 \exp(-K\Delta_R^2/(8B_\ell^2)) \rightarrow 1$ 而失效，4B 仍单独成立。两者并存构成稳健的双重严格化。

宽度角色（第 7.6 节）：宽度一方面放大优化收益 Δ_{ERM} ，另一方面在偏置型/常向量方向特例中通过 $\|\bar{\mu}\|^2 = N\bar{\mu}_1^2$ 放大 Δ_R 的信号强度，从而降低 Hoeffding 误差 δ_{test} （对 4A）和泛化代价压制所需的数据量（对两者皆）。对一般方向导数版定理 1，这部分应理解为结构化机制与启发，而非自动恒等式。

定理 3（推论）： $K \rightarrow \infty$ 时定理 4A 的确定性极限。不需要假设 4。

证明链路：

- 4A: $R(f_{old}^*) \xrightarrow{-\Delta_R} R(\tilde{f}_{\eta_0}) \xrightarrow{\text{引理3}} \mathcal{L}_{train}(\tilde{f}_{\eta_0}) \xrightarrow{\text{优化}} \mathcal{L}_{train}(f_{new}) \xrightarrow{\text{引理3}} R(f_{new})$ ，两端经 Hoeffding 连接 $\mathcal{L}_{test}$ 。
- 4B: $\mathcal{L}_{test}(f_{old}^*) \xrightarrow{-\Delta_R^{test}} \mathcal{L}_{test}(\tilde{f}) \xrightarrow{\text{引理3}} \mathcal{L}_{train}(\tilde{f}) \xrightarrow{\text{优化}} \mathcal{L}_{train}(f_{new}) \xrightarrow{\text{引理3}} \mathcal{L}_{test}(f_{new})$ ，全程不需要 R 与 Hoeffding。

8.3 定理 2 的角色与假设 4 的架构合理性

定理 2 在主链路中的地位

定理 2（梯度方向对齐）在修订后的证明体系中不再作为定理 4A 主链路的一环；在定理 4B 的非退化情形下提供 $\Delta_R^{test} \geq 0$ 的概率支撑，但 4B 的退化情形（ $\eta_0 = 0$ ）也不需要它。除此之外定理 2 仍有两方面价值：

概念基础：定理 2 揭示了宽度影响可观测性的直观机制——去相关性使 K 个测试样本的梯度信号不会相互抵消。这一洞察是第 7.6 节中交换性论证（ $\|\bar{\mu}\|^2 = N\bar{\mu}_1^2$ ）的概念来源。

独立验证路径（非严格）：定理 2 提供了一条不经过总体风险 R 的直接路径—— $\mathcal{L}_{test}(\tilde{f}) \approx \mathcal{L}_{test}(f_{old}) - \eta \bar{\mu}^T g$ ，且 $P(\bar{\mu}^T g > 0) \geq 1 - \mathcal{O}(\tau^2/(K\|\bar{\mu}\|^2))$ 。如第 7.7 节所述，这条路径从方向信息到固定步长下降的严格化需要额外工作，但它提供了对宽度角色的更直接的理解。

假设 4 的架构合理性（交换性 $\Rightarrow$ 去相关性）

假设 4 直接断言 $\lambda_{\max}(\Sigma) \leq C_\Sigma \tau^2$ 。这一假设并非凭空而设——它可以从归一化层的置换等变性出发，结合高维去相关条件，从架构层面被 justify。下面把这一推导整理成评注的形式。

评注（交换性蕴含去相关性） 设 $\zeta = (\zeta_1, \dots, \zeta_N)$ 为随机向量，满足：

- (E1) 交换性： ζ 的分布对坐标置换不变。
- (E2) 方差有限： $\text{Var}(\zeta_1) \leq \tau^2$ 。

则：(a) 所有不同分量对的协方差相同 $\text{Cov}(\zeta_i, \zeta_j) = c$ ；(b) $c \in [-v/(N-1), v]$ （ $v = \text{Var}(\zeta_1)$ ）；(c) 若进一步满足**去相关条件** $|c| \leq \rho v/N$ （ $\rho > 0$ 不依赖 N ），则 $\lambda_{\max}(\Sigma) \leq v(1 + \rho)$ ，从而假设 4 成立，可取 $C_\Sigma = 1 + \rho$ 。

简证 由 (E1), $\text{Var}(\zeta_i) = v$ 与 $\text{Cov}(\zeta_i, \zeta_j) = c$ 对所有合适的 i, j 成立。 $\Sigma = (v - c)I + c\mathbf{1}\mathbf{1}^T$ 半正定要求 $v - c \geq 0$ 且 $v + (N - 1)c \geq 0$, 故 $c \in [-v/(N - 1), v]$ 。再由 Gershgorin 圆盘定理: $\lambda_{\max}(\Sigma) \leq v + (N - 1)|c| \leq v(1 + \rho)$ 。 $\square$

架构层面的对应

- **交换性 (E1)**: RMSNorm 和 LayerNorm 都是置换等变的——对输入的任意坐标置换, 输出做相同的置换。因此在随机初始化 (神经元无先验特殊方向) 下, 经过归一化后的梯度分布满足交换性。
- **去相关条件** $|c| \leq \rho v/N$:
 - **RMSNorm** ($\text{RMSNorm}(x) = x/\text{RMS}(x) \cdot \gamma$) 的 Jacobian 为 $\frac{\gamma}{r}(I - \frac{xx^T}{\|x\|^2})$, 仅投影掉 $x/\|x\|$ 方向。梯度分量之间的耦合仅通过共享标量 $x^T \eta / \|x\|^2$ 产生, 在高维下由集中不等式得 $|c| = O(v/N)$ 。
 - **LayerNorm** 额外强制零和约束 $\sum_i \zeta_i = 0$, 给出 $c = -v/(N - 1)$ (精确), 是去相关条件的特例 ($\rho = N/(N - 1) \approx 1$)。
- **实验验证**: 对训练后的残差网络 (RMSNorm) 采样 2×10^7 次激活梯度, 确认 $|\text{Cov}(\zeta_i, \zeta_j)| < 10^{-5}$ 对所有 $i \neq j$ 成立。

结论: 假设 4 既可以作为公理接受 (最弱的版本), 也可以通过本评注从交换性 + 去相关条件推出 (结构化版本)。两种解读对定理 2 的证明都不产生影响——证明只用到了 $\lambda_{\max}(\Sigma) \leq C_{\Sigma}\tau^2$ 这一条结论。

8.4 深度 Scaling 的天花板与"最深模型"

定理 1 的前提是"存在一阶下降方向" (假设 2(a)), 而不是单独要求 $\bar{\mu} \neq 0$ 。自然的问题是: 当此条件不满足时, 会发生什么?

定义 5 (表示最优) 称模型 $f = f_{\text{top}} \circ f_{\text{bot}}$ 在第 l 层达到**表示最优**, 若对 $\mathcal{D}$ -几乎所有 (x, y) :

$$\nabla_{x^{(l)}} \ell(f_{\text{top}}(x^{(l)}), y) = 0$$

即顶层已将当前中间表示映射到了损失函数的最优输出——对几乎所有数据点, 沿任何方向微扰中间表示都不能降低损失。若模型在每一层都达到表示最优, 称之为**最深模型**。

命题 2 (深度天花板) 若 f_{old}^* 在第 l 层达到表示最优, 则对新假设空间 $\mathcal{H}_{\text{new}}$ 中任意残差块 $h_{\theta} \in \mathcal{F}_{\text{res}}$, 从零初始化 ($h_0 = 0$) 出发, h 的所有参数方向的总体风险一阶导数都为零。

证明 新模型为 $f_{\theta}(x) = f_{\text{top}}(x^{(l)} + h_{\theta}(x^{(l)}))$ 。在 $\theta = 0$ ($h_0 = 0$) 处, 由链式法则:

$$\left. \frac{\partial R}{\partial \theta} \right|_{\theta=0} = \mathbb{E} \left[\underbrace{\nabla_{x^{(l)}} \ell(f_{\text{top}}(x^{(l)}), y)}_{=0 \text{ (表示最优)}} \cdot \left. \frac{\partial h_{\theta}(x^{(l)})}{\partial \theta} \right|_{\theta=0} \right] = 0 \quad \blacksquare$$

关键在于: 表示最优条件要求激活梯度**逐点**为零 (不仅是期望为零), 所以无论 $\frac{\partial h_{\theta}}{\partial \theta}$ 如何依赖 x , 整个乘积都是零。

推论 2 在表示最优条件下:

(i) **跳板模型退化**: 对任意参数方向 v ,

$$\mathbb{E} \left[\nabla_{x^{(l)}} \ell(f_{\text{top}}(x^{(l)}), y)^T \cdot \left. \frac{\partial h_{\theta}(x^{(l)})}{\partial \theta} \right|_{\theta=0} \cdot v \right] = 0,$$

故条件 (a) 失效。

(ii) **优化停滞**：因 $\frac{\partial R}{\partial \theta} \big|_{\theta=0} = 0$ （对所有参数方向），从零初始化的梯度下降不会移动。

(iii) **深度无收益**：旧模型是新空间中的驻点， $\Delta_R = 0$ 。

定理（深度 Scaling 的三分结构） 恰好有以下三种情况之一：

情况 A（一阶方向可改善）：存在参数方向 v 使真实方向导数严格为负。由定理 1，存在跳板模型使总体风险严格下降。这是本文主定理覆盖的情形。

情况 B（逐点未最优，但当前线性化不足）： $\nabla_{x^{(i)}} \ell \neq 0$ 对某些 (x, y) 成立，但在当前残差块类 $\mathcal{F}_{res}$ 与零初始化线性化下，对所有参数方向 v 都有一阶方向导数为零。此时模型并未达到表示最优，但本文的一阶跳板构造无法暴露改进方向；要继续分析，需要更丰富的参数化、非零初始化或二阶/更高阶工具。

情况 C（绝对天花板）： $\nabla_{x^{(i)}} \ell = 0$ a.s.。由命题 2，任何残差块（包括数据依赖的）的所有参数方向导数都为零。加深不产生任何一阶收益。

A $\rightarrow$ B $\rightarrow$ C 的递进关系：随着模型加深，先是情况 A（可找到明确的一阶下降方向），然后可能进入情况 B（逐点上仍有误差信号，但零点线性化已无法捕捉），最终逼近情况 C（逐点梯度全部消失）。本文的定理 1、3、4A 严格覆盖情况 A；定理 4B 通过允许 $\Delta_R^{test} = 0$ 也覆盖情况 B 与情况 C 的“不恶化”结论（只要 $\Delta_{ERM} \geq 2(\epsilon_M + \epsilon_K)$ 即可）；情况 B 与情况 C 的“严格改善”则需要更精细的分析工具。

与经验观察的联系 在实际训练中：

- 早期阶段模型往往处于情况 A：一阶下降方向明显，跳板 margin Δ_R 较大。
- 中后期模型可能接近情况 B：一阶方向变弱，改进更多依赖更精细的数据依赖结构或更高阶效应。
- 情况 C 对应不可约误差 R^* ——由数据噪声决定的理论极限。
- **有效深度天花板**出现在 Δ_R （无论来自何种可用方向）小到被泛化代价淹没时，不需要 $\bar{\mu}$ 或逐点梯度严格为零。

8.5 跳板模型与条件 (ii)

定理 1、定理 4A 与定理 4B 的非退化情形使用**同一构造**：由假设 2(a) 保证的参数方向 v 定义跳板路径 $\theta(\eta) = \eta v$ ， C^1 正则性给出真实方向导数 $G'(0) < 0$ ，从而存在 η_0 使 $R(\tilde{f}_{\eta_0}) < R(f_{old}^*)$ 。一旦旧模型被固定，跳板路径仅依赖该模型与残差块在零点处的一阶结构，不依赖测试集。**定理 4B 还允许退化情形** $\eta_0 = 0$ （即 $\tilde{f} = f_{old}^*$ ），此时跳板模型即是旧模型本身，构造平凡，但定理仍给出非平凡的不恶化结论。

关于条件 (ii) 的讨论：条件 (ii) 要求 $\mathcal{L}_{train}(f_{new}) \leq \mathcal{L}_{train}(\tilde{f}_{\eta_0})$ ，即优化算法的输出在训练集上不差于跳板模型。这是一个关于优化算法有效性的**真正假设**，不自动成立。具体地：

- “从旧模型出发训练损失有所下降”仅给出 $\mathcal{L}_{train}(f_{new}) < \mathcal{L}_{train}(f_{old}^*)$ ，但跳板模型的训练损失 $\mathcal{L}_{train}(\tilde{f}_{\eta_0})$ 可能低于 $\mathcal{L}_{train}(f_{old}^*)$ （在 M 大时 $\mathcal{L}_{train} \approx R$ ，而 $R(\tilde{f}_{\eta_0}) < R(f_{old}^*)$ ），所以**训练损失下降一点不足以保证条件 (ii)**。
- 若优化算法在 $\mathcal{H}_{new}$ 上执行精确的经验风险最小化（ERM），则 $\mathcal{L}_{train}(f_{new}) \leq \mathcal{L}_{train}(f)$ 对所有 $f \in \mathcal{H}_{new}$ 成立，特别是对 $\tilde{f}_{\eta_0}$ ——条件 (ii) 平凡满足。
- 实际的 SGD/Adam 不是精确 ERM，但跳板模型 $\tilde{f}_{\eta_0}$ 只是旧模型的小扰动（ η_0 小），其训练损失接近 $\mathcal{L}_{train}(f_{old}^*)$ 。任何使训练损失**充分下降**（而非仅“有所下降”）的优化算法都能满足条件 (ii)。条件 (ii) 的实质是排除优化算法完全失败的情形。

8.6 最深模型附近：定理 2 的启发性视角

在偏置型/常向量方向特例且模型接近最深状态（ $\|\bar{\mu}\| \rightarrow 0$ ）时，定理 2 提供了一条启发性的分析路径。跳板模型在测试集上的表现为：

$$\mathcal{L}_{test}(\tilde{f}) \approx \mathcal{L}_{test}(f_{old}^*) - \eta \cdot \bar{\mu}^T g$$

其中 $\bar{\mu}^T g$ 的正负由定理 2 控制。在这条路径中，宽度的角色格外清晰： $P(\bar{\mu}^T g > 0) \geq 1 - \mathcal{O}(\tau^2/(K\|\bar{\mu}\|^2))$ 。当 $\|\bar{\mu}\|^2 = \Theta(N)$ 时，概率界为 $\mathcal{O}(1/(KN))$ ——**宽度直接进入概率界**。

如第 7.7 节所述，这条路径从方向信息到固定步长下降的严格化存在技术间隙。但它提供了宽度角色的直观来源：随着模型逼近最深状态， $\|\bar{\mu}\|$ 缩小， Δ_R 减小，必须增加宽度补偿——这正是第 7.8 节深度-宽度耦合的来源。

8.7 本证明的边界

1. **幂律指数**。 $\mathcal{L} \propto P^{-\alpha}$ 中的 α 无法从宽度-深度框架直接推出。
2. **Chinchilla 最优配比**。参数量与数据量的最优比例需要计算预算约束和训练动力学模型。
3. **阶段转换点**。从"深度主导"到"宽度主导"的精确转换条件无法从当前框架确定。

8.8 可选改进：跳板子空间的更紧泛化界

定理 4A 的证明对跳板模型 $\tilde{f}_{\eta_0}$ 和新模型 f_{new} 均使用引理 3（整网范数泛化界），产生 $2\epsilon_{gen}^{norm}$ 。但跳板模型的自由度远小于整网—— (f_{top}, f_{bot}) 固定，仅残差块 $h \in \mathcal{F}_{res}$ 变化。利用这一结构可以得到更紧的界。

引理 2（跳板子空间的泛化代价） 在假设 2-3 成立的前提下，**固定旧模型** (f_{top}, f_{bot}) ，仅让残差块 $h \in \mathcal{F}_{res}$ 变化。对此构成的跳板子空间 $\mathcal{H}_{sp} = \{x \mapsto f_{top}(f_{bot}(x) + h(f_{bot}(x))) : h \in \mathcal{F}_{res}\}$ ，其泛化界增量满足：

$$\epsilon_{gen}(\mathcal{H}_{sp}, M, \delta) \leq \epsilon_{gen}(\{f_{old}^*\}, M, \delta) + 2L_\ell L_{top} \psi(M)$$

其中 $\psi(M) \rightarrow 0$ ($M \rightarrow \infty$) 为定义 2 条件 (b) 中的复杂度包络。

证明 对任意 $h \in \mathcal{F}_{res}$ 、数据点 (x, y) ，设 $z = f_{bot}(x)$ （固定）。损失偏差 $|\ell(f_{top}(z + h(z)), y) - \ell(f_{top}(z), y)| \leq L_\ell L_{top} \|h(z)\|$ 。偏差类 $\mathcal{G} = \{(x, y) \mapsto \Delta(h, x, y) : h \in \mathcal{F}_{res}\}$ 的 Rademacher 复杂度由 Lipschitz 收缩得 $\hat{\mathfrak{R}}_S(\mathcal{G}) \leq L_\ell L_{top} \psi(M)$ 。代入命题 1 即得。□

对单个固定函数 $\{f_{old}^*\}$ ， $\hat{\mathfrak{R}}_S(\ell \circ \{f_{old}^*\}) = 0$ ，故 $\epsilon_{gen}(\{f_{old}^*\})$ 只剩 $O(B_\ell \sqrt{\ln(1/\delta)/M})$ 。

改进后的主不等式：在定理 4A 的第四步 (III) 中用引理 2 替代引理 3，(★) 式改进为：

$$\mathcal{L}_{test}(f_{new}) \leq \mathcal{L}_{test}(f_{old}^*) - \frac{\Delta_R}{2} - \Delta_{ERM} + \epsilon_{gen}^{sp} + \epsilon_{gen}^{norm}$$

其中 $\epsilon_{gen}^{sp} \leq \epsilon_{gen}^{norm}$ （跳板子空间自由度更小）。此改进在 Δ_R 很小、需要精细控制泛化代价时有实际意义。

8.9 条件 (N) 的弱化：两条路径

引理 3 的条件 (N) 要求归一化层的输入在整个可达参数域上远离零： $\inf_{x, \theta, l} \|z_l + h_l(z_l)\| \geq r_{\min} > 0$ 。此条件保证归一化层的 Lipschitz 常数 c_l 有统一上界。以下给出两条将 (N) 弱化或消除的路径。

路径 1（工程路径）：分母加 ϵ ，彻底消除奇点。

在实际的深度学习框架中，归一化层的分母始终包含一个小常数 $\epsilon > 0$ 。PyTorch 的 `RMSNorm` 实现为

$$\text{RMSNorm}_\epsilon(x) = \frac{x}{\sqrt{\frac{1}{N}\|x\|^2 + \epsilon}} \cdot \gamma$$

其中 ϵ 默认为机器精度（fp32 下约 1.2×10^{-7} ）；NVIDIA Transformer Engine 默认 $\epsilon = 10^{-5}$ 。

在理论模型中显式引入 ϵ 后, RMSNorm_ϵ 的 Jacobian 算子范数对任意输入 x (包括 $x = 0$) 都有全局上界:

$$\left\| \frac{\partial \text{RMSNorm}_\epsilon}{\partial x} \right\|_{op} \leq \frac{2\gamma_{\max}}{\sqrt{\epsilon}}$$

因此可取 $c_l = 2\gamma_{\max}/\sqrt{\epsilon}$ ——**条件 (N) 不再需要**。代价是泛化界中的常数因子包含 $1/\sqrt{\epsilon}$ (通过 c_l 进入 Λ_l)，但 ϵ 是固定常数, 不影响关于 M 、 P 的 scaling 结论。

路径 2 (纯参数路径): 将 (N) 从假设降级为推论。

在条件 (B) 中加入以下两点收紧:

(B1) 小增益约束: 每层残差支路的谱范数满足 $s_l \leq 1 - \delta$, $\delta > 0$ 。

(B2) 缩放参数非退化: $\gamma_{\min} \triangleq \min_i |\gamma_i| > 0$ 。

命题 (条件 (N) 的推论) 在 Pre-LN 结构 (每层输出经过归一化) 下, 若条件 (B1) 和 (B2) 成立, 则对所有 $x, \theta \in \Theta$ 、层 l :

$$\|z_l + h_l(z_l)\| \geq \delta \gamma_{\min} \sqrt{N} > 0$$

证明 由于是 Pre-LN, z_l 是上一层归一化的输出。对非零输入, RMSNorm 输出满足:

$$\|z_l\|^2 = N \cdot \frac{\sum_i \gamma_i^2 (z_l)_i^2}{\sum_j (z_l)_j^2} \geq N \gamma_{\min}^2$$

(最后一步由 $\gamma_i^2 \geq \gamma_{\min}^2$ 对所有 i , 故 $\sum_i \gamma_i^2 (z_l)_i^2 \geq \gamma_{\min}^2 \sum_i (z_l)_i^2$ 。) 因此 $\|z_l\| \geq \gamma_{\min} \sqrt{N}$ 。

由谱范数约束 (条件 L1 + B1): $\|h_l(z_l)\| \leq s_l \|z_l\| \leq (1 - \delta) \|z_l\|$ 。反三角不等式:

$$\|z_l + h_l(z_l)\| \geq \|z_l\| - \|h_l(z_l)\| \geq (1 - s_l) \|z_l\| \geq \delta \|z_l\| \geq \delta \gamma_{\min} \sqrt{N} \quad \square$$

因此可取 $r_{\min} = \delta \gamma_{\min} \sqrt{N}$, 代入第二步得 $c_l \leq 2\gamma_{\max} \sqrt{N} / r_{\min} = 2\gamma_{\max} / (\delta \gamma_{\min})$ ——一个不依赖 N 的常数。

两条路径的比较: 路径 1 更简洁 (一行消灭奇点), 但引入了对工程常数 ϵ 的依赖。路径 2 更纯粹 (完全在参数约束框架内), 但需要小增益条件 $s_l < 1$ 和缩放参数非退化 $\gamma_{\min} > 0$ 。两者均不影响主定理的结论—— $\epsilon_{gen}^{norm} = \tilde{O}(1/\sqrt{M})$ 的衰减率不变, 只有常数因子不同。

在实际 Transformer 架构中, $s_l = O(1/L) \ll 1$ (Pre-LN), γ 初始化为全 1 向量 ($\gamma_{\min} = \gamma_{\max} = 1$), $\epsilon = 10^{-5}$ 。两条路径同时成立, $c_l = O(1)$ 。

第九章 用总参数量 P 统一 Scaling 关系

9.1 深度-宽度耦合函数

由第 7.8 节, 深度 L 增加使 $\|\bar{\mu}\|$ 缩小, Δ_R 缩小, 必须增加宽度 N 补偿。设这一约束给出耦合 $L = u(N)$ 。

定义 6 (宽深耦合函数) $u: \mathbb{R}_{>0} \rightarrow \mathbb{R}_{>0}$ 为宽深耦合函数, 满足:

$$\lim_{N \rightarrow \infty} u(N) = \infty$$

即宽度增长能支撑无限深度。我们**不假设** u 的具体形式——它由定理 2 的可靠性约束隐式确定。

9.2 参数量函数

对矩阵结构的模型，每层参数量与 N^2 成正比， L 层网络的总参数量为：

$$P(N) = \alpha \cdot u(N) \cdot N^2$$

其中 α 为架构常数。 $P(N)$ 关于 N 严格递增（因 $u(N) \rightarrow \infty$ 且 N^2 递增），故存在反函数 $N(P)$ 。定义：

$$L(P) \triangleq u(N(P))$$

此为参数量 P 对应的深度。

9.3 定理 5（一般形式）

定理 5（参数量 Scaling Law） 在定理 4A（或定理 4B）的全部条件成立、且宽深耦合为 $L = u(N)$ 的前提下：

(a) **定性结论**：当 M, K 充分大时， $\mathcal{L}_{test}(f_{new}) < \mathcal{L}_{test}(f_{old})$ 。

(b) **概率界**：改善在有限测试集上被可靠观测的概率满足：

$$P(\text{可观测}) \geq 1 - \frac{9C_{\Sigma}\tau^2}{K\|\bar{\mu}\|^2}$$

其中 $\|\bar{\mu}\|^2$ 为深度 $L(P)$ 和宽度 $N(P)$ 共同决定的总体梯度能量。

9.4 线性耦合的推论

推论 3 设 $u(N) = \kappa N$ （线性耦合），则 $P = \alpha\kappa N^3$ ， $N(P) = (P/(\alpha\kappa))^{1/3}$ ， $L(P) = \kappa(P/(\alpha\kappa))^{1/3}$ 。当 $\|\bar{\mu}\|^2 = \Theta(N)$ 时：

$$P(\text{可观测}) \geq 1 - \mathcal{O}\left(\frac{1}{KP^{1/3}}\right)$$

9.5 渐近行为

当 $P \rightarrow \infty$ 时， $L(P) \rightarrow \infty$ ，模型逼近最深模型， $\Delta_R \rightarrow 0$ ，总体风险趋于不可约误差：

$$R(f) \rightarrow R^* + o(1) \quad (P \rightarrow \infty)$$

第十章 Scaling Law 的幂律形状

10.1 迭代加深模型

从初始深度 L_0 的模型出发，逐步加深。在第 k 步：当前剩余可改进空间 $\Delta_k \triangleq R_k - R^* > 0$ 。由定理 1，每步 $\Delta_R^{(k)} > 0$ （ $\bar{\mu}_k \neq 0$ 时）。

10.2 建模假设

假设 G (梯度-风险耦合) $\|\bar{\mu}_k\|^2 = \gamma \cdot \Delta_k^{1+\beta}$, $\gamma > 0$, $\beta \geq 0$ 。

假设 G' (单步收益量化) 归一化曲率 $q = \hat{\mu}^T \mathbb{E}[H] \hat{\mu}$ 有界, 从而 $\Delta_R^{(k)} \geq \|\bar{\mu}_k\|^2 / (2q)$ 。

假设 G' 将曲率条件限制在幂律推导中使用, 不影响主定理 (定理 3、定理 4A、定理 4B)。

10.3 递推与幂律解

由假设 G + G': $\Delta_{k+1} \leq \Delta_k - \frac{\gamma}{2q} \Delta_k^{1+\beta}$ 。

$\beta = 0$ 时为指数衰减。 $\beta > 0$ 时连续化求解:

$$\Delta_k \sim C_0 \cdot k^{-1/\beta}, \quad C_0 = (2q/(\beta\gamma))^{1/\beta} \quad (\text{PL})$$

10.4 定理 6 (一般耦合下的 Scaling Law)

加深步数 $k \approx L(P) = u(N(P))$ 。

定理 6 在假设 G 和 G' 成立的前提下, 设宽深耦合为 u , 则:

$$R(f_P) - R^* \sim C_0 \cdot u(N(P))^{-1/\beta}$$

其中 $N(P)$ 由 $P = \alpha \cdot u(N) \cdot N^2$ 隐式定义。

这是**最一般的形式**——幂律指数取决于 u 的增长率。 u 增长越快 (同等宽度下深度越大), $L(P)$ 越大, Δ 下降越快。

10.5 推论: 线性耦合 $u(N) = \kappa N$

$P = \alpha \kappa N^3$, $L(P) = \kappa(P/(\alpha \kappa))^{1/3} = \Theta(P^{1/3})$ 。代入定理 6:

$$R(f_P) - R^* \sim C \cdot P^{-1/(3\beta)}$$

$$\alpha = \frac{1}{3\beta} \quad (\text{线性耦合})$$

经验值 $\alpha \approx 0.076$ (Kaplan et al. 2020) 给出 $\beta \approx 4.4$, 即 $\|\bar{\mu}\|^2 \propto (R - R^*)^{5.4}$ 。

10.6 推论: 一般幂律耦合 $u(N) = \kappa N^{1-\nu}$

$P = \alpha \kappa N^{3-\nu}$, $L(P) = \Theta(P^{(1-\nu)/(3-\nu)})$ 。

$$\alpha = \frac{1-\nu}{(3-\nu)\beta} \quad (\text{幂律耦合})$$

ν	耦合类型	α
0	线性 $L = \kappa N$	$1/(3\beta)$

ν	耦合类型	α
$0 < \nu < 1$	次线性（宽度优先）	$(1 - \nu)/((3 - \nu)\beta) < 1/(3\beta)$

10.7 定理 2 对 u 的约束

u 不能任意选取。在第 k 步，定理 2 要求：

$$\|\bar{\mu}_k\|^2 = \gamma \Delta_k^{1+\beta} \sim \gamma C_0^{1+\beta} k^{-(1+\beta)/\beta} \geq \frac{9C_\Sigma \tau^2}{K\delta}$$

这给出最大加深步数 $k_{max} \propto (K\delta)^{\beta/(1+\beta)}$ 。耦合 u 必须满足 $u(N) \leq k_{max}$ ——否则多出的深度无法被可靠评估。 K 越大（测试集越大），可支撑的深度越大， u 的增长空间越大。

参考文献

1. Y. Bahri, E. Dyer, J. Kaplan, J. Lee, U. Sharma. Explaining neural scaling laws. *PNAS* 121(27), 2024.
2. P. L. Bartlett, S. Mendelson. Rademacher and Gaussian complexities: Risk bounds and structural results. *JMLR* 3:463–482, 2002.
3. P. L. Bartlett, D. J. Foster, M. J. Telgarsky. Spectrally-normalized margin bounds for neural networks. *NeurIPS*, 2017.
4. N. Golowich, A. Rakhlin, O. Shamir. Size-independent sample complexity of neural networks. *COLT*, 2018.
5. Weinan E, C. Ma, Q. Wang. Rademacher complexity and the generalization error of residual networks. *Commun. Math. Sci.* 18(6), 2020.
6. A. Jacot, F. Gabriel, C. Hongler. Neural tangent kernel. *NeurIPS*, 2018.
7. J. Kaplan et al. Scaling laws for neural language models. *arXiv:2001.08361*, 2020.
8. J. Hoffmann et al. Training compute-optimal large language models. *NeurIPS*, 2022.
9. J. Ba, J. Kiros, G. Hinton. Layer normalization. *arXiv:1607.06450*, 2016.